

بنام خداوند جان و



دانشکده مهندسی برق و کامپیوتر
گروه مهندسی الکترونیک

پایان نامه

جهت دریافت درجه کارشناسی ارشد در رشته مهندسی برق - الکترونیک

عنوان:

طراحی سیستم تشخیص فعالیتهای تشنجی با استفاده از روشهای یادگیری عمیق از روی سیگنال
های الکتروکورتیکوگرافی در موش صحرایی

استاد راهنما:

دکتر جواد فرونچی

استاد مشاور:

دکتر عماد خلیل زاده

پژوهش گر:

مصطفی پیران شندرشامی

زمستان ۱۴۰۱

تشکر و قدردانی

اکنون که به لطف خدای مهربان، نگارش این پایان نامه به اتمام رسیده است بر خود لازم میدانم که از زحمات اساتید گرانقدر، جناب آقای دکتر فرونچی و جناب آقای دکتر خلیل زاده که در مراحل مختلف مرا یار نموده‌اند و افزون بر آن در طول دوره‌ی تحصیلی در مقطع کارشناسی ارشد مرا از دانش خود بهرمند ساخته‌اند سپاس گذاری کنم و ارزوی قلبی من است که در تمام مراحل زندگی سربلند و پیروز باشند. و در ادامه از تمام دوستانی که در این راه به من کمک و مشورت دادن و مایه دل گرمی من بودن تشکر میکنم و ارزوی سلامتی برایشان دارم.

تقدیم به مادر عزیزم و تمام کسانی که به خاطر علم از خودگذشتگی کردن.

اینجان‌ب مصطفی پیران شندرشامی دانشجوی مقطع کارشناسی ارشد رشته مهندسی برق گرایش مدارهای مجتمع الکترونیکی دانشکده مهندسی برق و کامپیوتر دانشگاه تبریز تایید می‌نمایم:

- مطالب ارائه‌شده در این پایان‌نامه با عنوان: طراحی سیستم تشخیص فعالیت‌های تشنجی با استفاده از روش‌های یادگیری عمیق از روی سیگنال‌های الکتروکورتیکوگرافی در موش صحرایی

که در ادامه به اختصار پایان‌نامه نامیده می‌شود حاصل تحقیقات اینجان‌ب تحت راهنمایی آقای دکتر جواد فرونچی و مشاوره آقای دکتر عماد خلیل‌زاده در دانشگاه تبریز است و در صورت استفاده از نتایج پژوهش‌ها و یا آثار دیگران بلافاصله به مرجع مورد استفاده استناد شده است و در قسمت منابع و مآخذ مشخصات مرجع به‌طور کامل ذکر گردیده است.

- مسئولیت صحت مطالب مندرج در این پایان‌نامه به‌طور کامل با اینجان‌ب است.

- تحقیقات مندرج در این پایان‌نامه که بدون استناد باشند توسط اینجان‌ب یا فرد دیگری تاکنون برای دریافت هیچ نوع مدرک یا امتیازی در هیچ‌جا ارائه نگردیده است.

- کلیه حقوق مادی و معنوی این پایان‌نامه و هر گونه محصول مستخرج از آن اعم از مقالات، برنامه‌های رایانه‌ای و تجهیزات ساخته‌شده به دانشگاه تبریز تعلق دارد و هرگونه استفاده از اطلاعات و یا نتایج، واگذاری اطلاعات به افراد دیگر، چاپ، تکثیر، نسخه‌برداری، ترجمه و اقتباس از این پایان‌نامه بدون اخذ اجازه کتبی از دانشگاه تبریز ممنوع است.

- کلیه مقالات مستخرج از این پایان‌نامه تحت نام دانشگاه تبریز (University of Tabriz) به‌عنوان وابستگی نویسنده اول و با اجازه استاد راهنمای اول به چاپ رسیده یا خواهد رسید.

در صورت اثبات تخلف در هر زمان، دانشگاه تبریز حق پیگیری قانونی خواهد داشت.

نام و نام خانوادگی دانشجو: مصطفی پیران شندرشامی

امضا و تاریخ: ۱۴۰۱/۱۱/۱۹

نام خانوادگی: پیران شندرشامی			نام: مصطفی		
عنوان پایان نامه: طراحی سیستم تشخیص فعالیتهای تشنجی با استفاده از روشهای یادگیری عمیق از روی سیگنال های الکتروکورتیکوگرافی در موش صحرایی					
استاد راهنما: دکتر جواد فرونچی			استاد مشاور: دکتر عماد خلیلزاده		
مقطع تحصیلی: کارشناسی ارشد		رشته: مهندسی برق		گرایش: الکترونیک	
دانشگاه: تبریز		دانشکده: مهندسی برق و کامپیوتر			
تاریخ فارغ التحصیلی: ۱۴۰۱/۱۱/۱۹ تعداد صفحات: ۶۵					
کلید واژه‌ها: تشخیص تشنج، الکتروکورتیکوگرافی (ECoG)، الکتروانسفالوگرام (EEG)، یادگیری عمیق، پنتیلن تترازول (PTZ)، شبکه‌های کانولوشنی، صرع					
<p>چکیده:</p> <p>بر اساس گزارش سازمان بهداشت جهانی، صرع شایع ترین اختلال مغزی است که تقریباً پنجاه میلیون نفر را در سراسر جهان تحت تاثیر قرار می دهد. تشخیص صرع به بازرسی دستی نوار مغزی متکی است که مستعد خطا و زمان بر است. تشخیص خودکار تشنج صرع از روی سیگنال EEG و یا ECoG می تواند زمان تشخیص را کاهش دهد و هدف گذاری درمان را برای بیماران تسهیل کند. رویکردهای تشخیص کنونی عمدتاً بر ویژگی هایی متکی هستند که به صورت دستی توسط متخصصان موج و سیگنال طراحی شده اند. ویژگی ها برای تشخیص انواع الگوهای پیچیده در حجم زیادی از داده های EEG انعطاف ناپذیر هستند. علاوه بر این، EEG و ECoG سیگنال غیر ثابت هستند و الگوهای تشنج در بیماران و جلسات ضبط متفاوت است. داده های EEG و ECoG همیشه حاوی انواع نویزهای متعددی است که بر دقت تشخیص تشنج های صرعی تأثیر منفی می گذارد. برای پرداختن به این چالش ها، رویکردهای یادگیری عمیق در این مقاله مورد بررسی قرار گرفته است. داده های مورد استفاده در این تحقیق از نمونه های حیوانی (موش صحرایی) جمع اوری شده و تشنج ها به صورت غیر طبیعی توسط دارو ایجاد شده است. داده های سری زمانی بدون هیچ فیلتر خاصی به شبکه یادگیری عمیق اعمال شده اند. تنها فیلتر مورد استفاده فیلتر ناچ ۵۰ هرتز برق شهری است. بعد از مطالعه و مقایسه شبکه های کانولوشنی برای طبقه بندی داده های این تحقیق انتخاب و استفاده شد. که بهترین نتیجه با دقت ۹۵.۲۲٪ و خطای ۱۷.۹۸٪ به دست آمد. شبکه طراحی شده نتایج امیدوارکننده ای را برای ساخت آشکارسازهای تشنج شخصی سازی شده تولید کرد. برای افزایش دقت و کاهش خطا داده های کافی در دسترس نبود.</p>					

فهرست مطالب

۱. مقدمه	۹
۲. مبانی و پیشینه تحقیق	۱۰
۲.۱. صرع و نوار مغزی	۱۰
۲.۱.۱. تعریف صرع و تشنج صرعی	۱۰
۲.۱.۲. بررسی علل صرع	۱۰
۲.۱.۳. طبقه‌بندی انواع تشنج	۱۲
۲.۱.۴. بحران صرعی یا صرع پایدار	۱۵
۲.۱.۵. منشأ EEG	۱۶
۲.۱.۶. ثبت و فعال سازی EEG	۱۸
۲.۱.۷. EEG در تشخیص صرع و بحران صرعی	۱۹
۲.۱.۸. تفسیر EEG	۲۱
۲.۱.۹. ECOG در مقابل EEG	۲۴
۲.۱.۱۰. ناهنجاری های صرعی	۲۵
۲.۱.۱۱. مصنوعات EEG	۲۹
۲.۲. یادگیری عمیق	۳۰
۲.۲.۱. بررسی اجمالی	۳۰
۲.۲.۲. شبکه های عصبی مصنوعی	۳۱
۲.۲.۳. دسته بندی تعدادی از شبکه های عصبی عمیق	۳۳
۲.۲.۴. معماری ها	۳۴
۲.۲.۴.۱. شبکه های فیدبک عمیق	۳۴
۲.۲.۴.۲. شبکه های عصبی کانولوشنال	۳۷
۲.۲.۴.۳. شبکه های حافظه کوتاه مدت مکرر و بلند مدت	۳۹
۲.۲.۵. تنظیم شبکه های عصبی عمیق	۴۰
۲.۲.۶. گردش کار یادگیری عمیق در پردازش سیگنال	۴۲
۲.۳. کارهای مرتبط	۴۳
۳. مواد و روشها	۴۶
۳.۱. مقدمه	۴۶

۴۶.....	۳.۲. جمع آوری داده‌ها.....
۴۶.....	۳.۲.۱. موش ها.....
۴۶.....	۳.۲.۲. جراحی و کاشت الکتروود ها.....
۴۷.....	۳.۲.۳. ثبت سیگنال ECoG.....
۴۸.....	۳.۳. طراحی شبکه عمیق.....
۴۸.....	۳.۳.۱. سامانه ها و کتابخانه های مورد استفاده.....
۴۹.....	۳.۳.۲. پیش پردازش داده ها.....
۵۱.....	۳.۳.۳. انتخاب شبکه عمیق مناسب.....
۵۲.....	۳.۳.۴. طراحی و تنظیم پارامترهای شبکه CNN_2D.....
۵۲.....	۳.۳.۴.۱. لایه‌ی Convolutional.....
۵۳.....	۳.۳.۴.۲. لایه‌ی BatchNormalization.....
۵۳.....	۳.۳.۴.۳. لایه‌ی Pooling.....
۵۳.....	۳.۳.۴.۴. لایه‌ی Flatten.....
۵۳.....	۳.۳.۴.۵. لایه‌ی Fully-Connected.....
۵۳.....	۳.۳.۴.۶. لایه‌ی Dropout.....
۵۴.....	۳.۳.۴.۷. لایه‌ی ActivityRegularization.....
۵۴.....	۳.۳.۴.۸. ساختار نهایی شبکه عمیق طراحی شده.....
۵۶.....	۳.۳.۵. آموزش شبکه.....
۵۷.....	۴. نتایج و بحث.....
۵۷.....	۴.۱. نتایج به دست آمده.....
۵۸.....	۴.۲. بحث و نتیجه گیری.....
۵۹.....	۴.۳. پیشنهادات.....
۶۰.....	مراجع.....

۱. مقدمه

صرع شایع ترین اختلال عصبی جدی است. تعداد افراد مبتلا به صرع از هر هزار نفر در سراسر جهان سه نفر است. در چندین منطقه، درصد بیماران صرعی در یک جمعیت حدود ۴ درصد است که به معنای ۴۰ نفر در هر هزار نفر است. هر سال در بین هر ۱۰۰۰۰۰ نفر ۴۰ تا ۷۰ نفر جدید مبتلا به صرع خواهند بود. صرع می تواند در هر سنی رخ دهد، اما افراد بالای ۶۵ سال بیشتر از ۲۵ تا ۵۵ سال ها به آن مبتلا می شوند [۱].

الکتروانسفالوگرام (EEG) تکنیکی است که معمولاً برای نظارت بر فعالیت مغز و تشخیص صرع استفاده می شود. ضبط EEG توسط متخصصان مغز و اعصاب برای تشخیص و شناسایی تشنج های صرع تجزیه و تحلیل می شود. معاینه بصری یک کار پر زحمت و زمان بر است. شناسایی صرع، به حداقل رساندن تاخیر در درمان و یافتن سطح بهینه مراقبت های بهداشتی از جنبه های حیاتی در درمان صرع است. کارهای تحقیقاتی زیادی برای طبقه بندی خودکار سیگنال های صرعی و غیرصرعی انجام شده است. از نقطه نظر یادگیری ماشینی، طبقه بندی سیگنال های صرعی و غیرصرعی یک کار چالش برانگیز است. دلیل آن کمبود داده های موجود برای آموزش یک طبقه بندی کننده است. علاوه بر این، وجود نویز، تداخل، و خطا در سیگنال های EEG باعث ایجاد چالش هایی در یادگیری الگوهای مغزی مرتبط با سیگنال های EEG تشنجی و غیر تشنجی می شود. صرع یک موجودیت بیماری منفرد نیست، بلکه انواع اختلالات ناشی از اختلالات مختلف مغز است. بنابراین انواع مختلفی از الگوهای پیچیده تشنج وجود دارد [۲].

با توجه به تمام جوانب در این تحقیق از نمونه های حیوانی شامل ۱۳ موش نژاد ویستار استفاده شد برای ضبط سیگنال مغزی شامل تشنج های صرعی که توسط دارو در زمان های مشخص ایجاد میشد. برای به دست آوردن سیگنال های تمیزتر نسبت به EEG از تکنیک ضبط سیگنال به روش ECOG استفاده شد.

برای طبقه بندی از ساختار CNN شبکه های عمیق استفاده شد البته باید توجه داشت که به علت محدودیت های که در حجم داده داشتیم دقت شبکه از حدی بالاتر نتوانستیم بهبود دهیم با این حال شبکه طراحی شده به دقت ۹۵.۲۲٪ درصد رسید با توجه به خطای ۵ تا ۱۰ درصدی تشخیص انسانی دقت شبکه ما بهتر از این رنج عمل میکند [۳].

۲. مبانی و پیشینه تحقیق

۲.۱. صرع و نوار مغزی

۲.۱.۱. تعریف صرع و تشنج صرعی

صرع به عنوان یک اختلال عصبی مزمن مغزی تعریف می‌شود که در آن مغز تمایل غیرطبیعی طولانی‌مدتی برای ایجاد تشنجهای صرعی دارد. صرع تنها یک بیماری نیست، بلکه انواع اختلالات ناشی از عدم عملکرد مناسب قسمت‌های مختلف مغز است. تشنج صرعی به عنوان "یک رخداد گذرا از علائم ناشی از فعالیت عصبی غیر طبیعی بیش از حد یا همزمان در مغز" تعریف می‌شود [۴].

تشخیص صرع مستلزم وقوع حداقل یک تشنج صرعی و غیرطبیعی است که در تصویربرداری تشدید مغناطیسی مغز یا نوار مغزی (EEG¹) مشاهده می‌شود. طول مدت تشنج صرعی از چند ثانیه تا چند دقیقه متغیر است. فردی که از صرع رنج می‌برد؛ همواره با پیامدهای عصبی، شناختی، روانی یا اجتماعی ناشی از این بیماری دچار مشکلاتی است [۵].

۲.۱.۲. بررسی علل صرع

صرع چیزی بیش از تشنجهای خودبه‌خودی و غیر ارادی است. صرع یک اختلال عصبی است که در آن فرد تغییرات طولانی‌مدت قابل مشاهده و غیرطبیعی در مغز دارد. یافتن علت صرع مهمترین بخش تشخیص آن است؛ زیرا امکان درمان موثر و کارآمدتری را برای اختلال مغزی که پشت صرع پنهان شده فراهم می‌سازد. در برخی موارد، صرع ژنتیکی است، اما اغلب در اثر آسیب مغزی، عفونت، ضربه، سکته، تومور مغزی یا ناهنجاری‌های مشابه ایجاد می‌شود. با این حال، عمدتاً علت صرع ناشناخته است [۶].

علت صرع را می‌توان به صورت ژنتیکی، ساختاری، عفونی، متابولیک، ایمنی و ناشناخته تقسیم‌بندی کرد (شکل ۱.۱). صرع ناشی از علل ژنتیکی مستقیماً از یک جهش ژنتیکی شناخته شده یا فرضی ناشی می‌شود. در موارد خاص، این علل ژنتیکی می‌تواند شامل یک نقص کروموزومی یا یک خطای ژنتیکی باشد. در بیشتر موارد، ژن‌های زمینه‌ای که منجر به بروز صرع می‌شوند، هنوز شناخته شده نیستند. علت ژنتیکی یک بیماری به معنای ارثی بودن آن نیست، زیرا جهش‌های جدید مدام در حال تکامل هستند. لازم به ذکر است که عوامل محیطی در ایجاد صرع نقش موثری دارند و بنابراین، علت ژنتیکی از اهمیت تاثیر عوامل محیطی نمی‌کاهد [۷].

در بررسی علت ساختاری صرع، ناهنجاری ساختاری به طور قابل توجهی احتمال بروز صرع را در فرد افزایش می‌دهد. یک ناهنجاری ساختاری ریشه در عوامل ژنتیکی، اکتسابی یا هر دو دارد. علل اکتسابی نظیر سکته مغزی، ضربه و آسیب فیزیکی، عفونت یا بروز اختلال عروق مغزی است. همانگونه که ذکر شد، در برخی موارد ناهنجاری‌های ساختاری ممکن

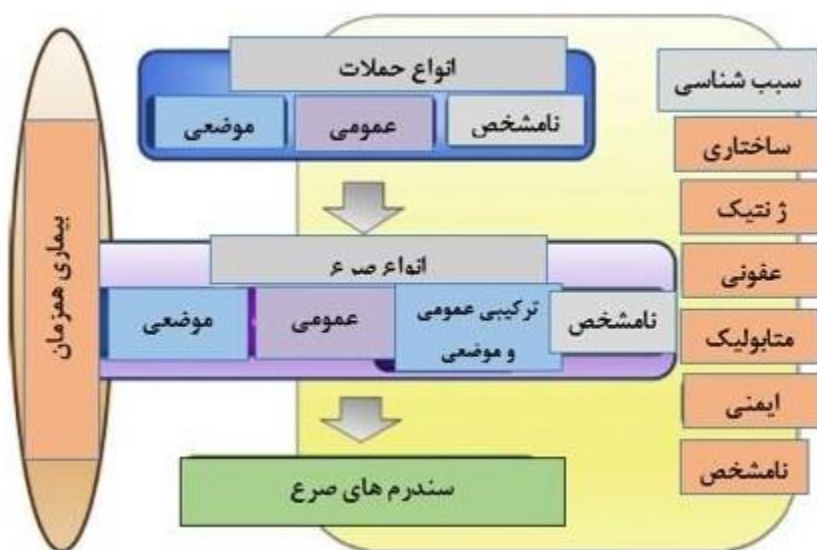
¹ Electroencephalography

است با جهش‌های ژنتیکی همراه باشد. ناهنجاری‌های ساختاری را می‌توان از طریق تصویربرداری عصبی مغز شناسایی کرد [۸].

علل متابولیکی صرع مربوط به وضعیت متابولیک یا وجود یک اختلال متابولیک در مغز است. دانشمندان بر روی درک اختلالات متابولیک مغز و ارتباط بین ناهنجاری‌های متابولیک و صرع در حال تحقیق هستند. اخیراً مشخص شده است که صرع ناشی از متابولیک مستقیماً از یک اختلال متابولیک شناخته شده یا فرضی ناشی می‌شود. با این وجود، اغلب اختلالات متابولیک نیز ژنتیکی هستند، اما عاملی که باعث تشنج صرعی می‌شود، نقص متابولیکی در افراد است [۹].

در حال حاضر، فعالیت غیر طبیعی مکانیسم دفاعی-ایمنی به عنوان یکی از علل صرع شناسایی شده است. صرع ایمنی مستقیماً از اختلال ایمنی ناشی می‌شود. در یک اختلال ایمنی، التهاب سیستم عصبی مرکزی منجر به خودایمنی شده که در آن عملکرد دفاعی بدن را به حمله علیه خود تبدیل می‌کند. امروزه، زمینه‌های اختلالات ایمنی در حال شناسایی می‌باشد که باعث تشخیص سریع این اختلالات می‌شود [۱۰].

شایع‌ترین علت ایجاد صرع عفونت است. در بررسی علت عفونی صرع مستقیماً از یک عفونت شناخته شده ناشی می‌شود؛ که در آن تشنج یکی از علائم اصلی این اختلال است. باکتری‌ها، ویروس‌ها، قارچ‌ها و تک یاخته‌ها می‌توانند باعث عفونت در مغز و در نتیجه آسیب به مغز شوند. در نهایت، آسیب مغزی ناشی از عفونت می‌تواند منجر به ایجاد صرع شود. صرع می‌تواند در مرحله حاد یا پسا حاد رخ دهد [۱۱].



شکل ۱.۱. دسته بندی انواع صرع [۸۴].

۲.۱.۳. طبقه‌بندی انواع تشنج

مطالعه بر روی شبکه‌های تشنج صرع در حال توسعه است، اما هنوز کارهای زیادی برای انجام دادن برای طبقه‌بندی تشنج وجود دارد. در سال ۱۹۸۱، کمیسیون بین‌المللی ضد صرع (ILAE) مطالعه‌ای را انجام داد که در آن صدها تصویربرداری ویدئویی-EEG از تشنجهای تحلیل و بررسی شد که تشنجهای را به حمله جزئی و کلی، تشنجهای جزئی ساده و پیچیده و انواع مختلف تقسیم می‌کردند. این طبقه‌بندی به عنوان اساس طبقه‌بندی تشنج در ابعاد گسترده به کار می‌رود. طبقه‌بندی‌های قبلی تشنج بر پایه آناتومی بوده است، اما رویکرد مدرن جدید ارائه شده صرع را به عنوان یک بیماری شبکه‌ای تعریف می‌کند [۱۲].

انواع مختلفی از طبقه‌بندی تشنج برای کاربردهای مختلف وجود دارد، اما این اطلاعات تنها به دیدگاه بالینی مبتنی بر الگوهای EEG توجه می‌کند و از طبقه‌بندی تشنج صرعی کنونی و اصطلاحات ILAE² استفاده می‌کند (شکل ۲.۲). در اهداف بالینی، طبقه‌بندی نوع تشنج عامل مهمی برای تشخیص و درمان صرع است. اولین کار در تشخیص اختلال صرع این است که مشخص شود حمله دارای ویژگی‌های تشنج است و مرحله دوم تشخیص نوع تشنج است. طبقه‌بندی تشنجهای صرعی هنوز هم بیشتر بر اساس نظر و مشاهدات متخصصین مغز و اعصاب است. همچنین EEG نمی‌تواند به تنهایی برای طبقه‌بندی تشنجهای صرعی مورد استناد باشد [۱۳].

طبقه‌بندی کنونی تشنج طبق شکل ۲.۲ بر اساس ویژگی‌های زیر است: محل شروع تشنج در مغز، سطح آگاهی در طول تشنج و سایر ویژگی‌های مربوط به تشنج. تعیین محل شروع تشنج در مغز یکی از عوامل بسیار مهم است؛ زیرا بر انتخاب داروی تشنج و جراحی‌های احتمالی تأثیر می‌گذارد. تشنجهایی که بر اساس محل شروع تشنج تعریف می‌شوند به تشنجهای کانونی، منتشر و شروع ناشناخته تقسیم می‌شوند.

سطح آگاهی فرد در آغاز و در حین حمله، تشنج را به چهار دسته تشنجهای کانونی آگاهانه، اختلال در آگاهی کانونی، آگاهی ناشناخته و عمومی تقسیم می‌کند. توصیف آگاهی عامل مهمی برای ایمنی فرد است. علائم حرکتی در تشنج کانونی و منتشر به دو دسته تشنج حرکتی و غیر حرکتی تقسیم می‌شود. گاهی اوقات علت شروع یک تشنج مشخص نیست، سپس تشنج به عنوان یک تشنج از نوع شروع ناشناخته توصیف می‌شود. تشنجهای شروع ناشناخته نیز به دو دسته تشنج حرکتی و غیر حرکتی تقسیم می‌شوند [۱۴].

² International League Against Epilepsy

دسته بندی جدید تشنج های صرعی

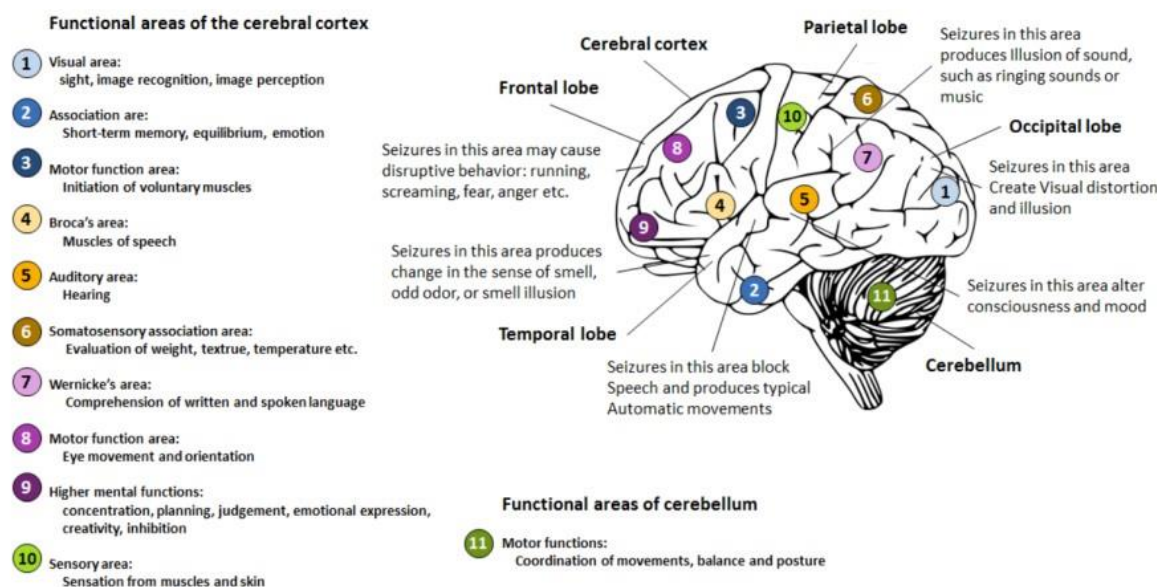


شکل ۲.۲. دسته بندی ILAE تشنج های صرعی [۸۴].

ویژگی های توصیف شده از عوامل کلیدی برای طبقه بندی نوع تشنج هستند. انواع تشنج بر اساس ویژگی ها به انواع تشنج های کانونی، منتشر و ناشناخته تقسیم می شوند (شکل ۲.۲). انواع مختلف صرع که ویژگی های تشنج عمومی را دارند، معمولاً ژنتیکی هستند و از دوران کودکی شروع می شوند. مشخصه اصلی تشنج عمومی این است که تخلیه الکتریکی از یک نقطه موضعی شروع می شود و در ناحیه وسیع تری از مغز گسترش می یابد. لازم به ذکر است تشنج های منتشر در ابتدا شبکه های دو طرف مغز را درگیر می کنند. تخلیه الکتریکی ممکن است از طریق پل مغزی (کوریپوس کالوزوم^۳) به سرعت از یک نیمکره به نیمکره دیگر پخش شود. انواع مختلف تشنج منتشر بر آگاهی یا هوشیاری تأثیر دارند؛ به همین دلیل است که تنها ویژگی های حرکتی و غیر حرکتی برای تقسیم انواع تشنج منتشر استفاده می شود. تشنج های حرکتی عمومی به انواع تشنج تونیک-کلونیک، کلونیک، تونیک، میوکلونیک، میوکلونیک-تونیک-کلونیک، میوکلونیک-آتونیک، آتونیک و تشنج اسپاسم صرعی تقسیم می شوند (شکل ۲.۲). ویژگی اصلی تشنج های حرکتی منتشر، سفت شدن یا تکان دادن بدن است [۱۵].

³ Corpus Callosum

صرع‌هایی که ویژگی‌های تشنج کانونی را دارند، معمولاً در بزرگسالی آغاز می‌شوند. تشنج کانونی در ناحیه یا شبکه‌ای از سلول‌های یک سمت مغز شروع می‌شود. تشنج کانونی ممکن است در هر بخش عضلانی (لوب^۴) یا نیمکره‌ی مغز رخ دهد، اما بیشتر در لوب‌های گیجگاهی (تمپورال^۵) یا پیشانی (فرونتال^۶) دیده می‌شود. محل و ناحیه پخش‌کننده تخلیه الکتریکی در مغز با علائمی مرتبط است که در اثر تشنج ایجاد می‌شود (شکل ۲.۳). تشنج‌های کانونی بر اساس آگاهی و علائم حرکتی دارای انواع مختلفی می‌باشد. تشنج‌های کانونی بر اساس هوشیاری به صورت تشنج‌های کانونی آگاهانه، اختلال کانونی و تشنج‌های کانونی که به تشنج تونیک-کلونیک دو طرفه تبدیل می‌شوند، گروه بندی می‌شوند [۱۶].



شکل ۲.۳. نواحی عملکردی قشر مخ، مخچه و رابطه آنها بین تشنج کانونی و علائم [۱۸].

تشنج‌های حرکتی کانونی به انواع تشنج‌های اتوماتیسم، آتونیک، کلونیک، اسپاسم صرعی، هایپرکینتیک، میوکلونیک و تشنج تونیک تقسیم می‌شوند (شکل ۲.۲). از ویژگی‌های اولیه تشنج‌های حرکتی کانونی می‌توان به سفتی یا تکان دادن بدن، از دست دادن تونوس عضلانی^۷ (انقباض خفیف و پیوسته ماهیچه) است. تشنج‌های غیرحرکتی کانونی به انواع تشنج‌های روانی (اتونومیک)، ایست رفتاری، شناختی، عاطفی یا حسی تقسیم می‌شوند. ویژگی‌های اولیه تشنج‌های غیرحرکتی مربوط به احساس، عواطف، تفکر یا تجربه است و در ابتدای تشنج غیرحرکتی رخ می‌دهد [۱۷].

⁴ Lobe

⁵ Temporal

⁶ Frontal

⁷ Muscle Tone

۲.۱.۴. بحران صرعی یا صرع پایدار

بحران صرعی^۸ (SE) یک شرایط جدی و حاد است؛ که در آن تشنج صرعی یا یک سری تشنج بدون هیچ بهبودی بیش از دوره زمانی تعریف شده طول می‌کشد. به طور کلی، اگر تشنج صرعی بیش از ۵ دقیقه طول بکشد، این وضعیت نیاز به مراقبت‌های ویژه دارد. بحران صرعی یک تشنج صرعی است که بیش از ۳۰ دقیقه طول می‌کشد. تشنج‌های طولانی مدت به دلیل ناتوانی و نقص در مکانیسم مسئول برای خاتمه تشنج یا شروع مکانیسم‌های غیرطبیعی ایجاد می‌شوند. بحران صرعی شرایطی است که با یک تشنج صرعی مشخص می‌شود که به اندازه کافی طولانی بوده یا در فواصل کوتاه به اندازه کافی تکرار می‌شود تا یک وضعیت صرعی نامتغیر و پایدار ایجاد کند.

بحران صرعی ممکن است پس از اختلال حاد یا مزمنی که بر سیستم عصبی مرکزی تأثیر می‌گذارد مانند سکته مغزی، عفونت سیستم عصبی مرکزی، آسیب مغزی، سندرم متابولیک، عدم تعادل الکترولیت ظاهر شود. بحران صرعی بسته به نوع و مدت تشنج ممکن است منجر به مرگ نوروها، آسیب عصبی و ایجاد تغییر در شبکه‌های عصبی شود، بنابراین بحران صرعی باید به سرعت مورد درمان قرار گیرد. گزارش شده است که به طور متوسط ۲۰٪ موارد صرع کشنده بوده و میزان مرگ و میر طولانی مدت در کودکان ۲۲٪ و ۵۷٪ در بزرگسالان است. تقریباً یک سوم از بیماران مبتلا به بحران صرعی جان خود را از دست می‌دهند، یک سوم دیگر به درجات مختلف نقص عصبی دائمی دچار می‌شوند و یک سوم باقی‌مانده به طور کامل بهبود می‌یابند [۱۸].

بحران صرعی را می‌توان به حالت صرع تشنجی و صرع غیرتشنجی تقسیم کرد. وضعیت صرع تشنجی شامل علائم حرکتی و وضعیت صرع غیر تشنجی دارای علائم غیر حرکتی است. بحران صرعی غیر تشنجی شامل از دست دادن هوشیاری، توهم یا علائمی است که مشاهده آنها دشوارتر از علائم حرکتی است. بحران صرعی تشنجی و غیر تشنجی بر اساس ثبت EEG به دو دسته عمومی و کانونی تقسیم می‌شود. به طور خاص، بحران صرعی به پنج نوع تقسیم می‌شود: SE-۱ تونیک-کلونیک، SE-۲ غایب، SE-۳ میوکلونیک، SE-۴ کانونی با اختلال هوشیاری، SE-۵ کانونی بدون اختلال هوشیاری. بحران صرعی تونیک-کلونیک شایع ترین نوع صرع پایدار است و ۷۰ درصد از کل موارد قابل درمان را تشکیل می‌دهد [۱۹].

تشخیص زود هنگام تنها برای ۳۰ تا ۶۰ درصد از بیماران مبتلا به صرع قابل انجام است. برای مثال در کشوری مثل فنلاند بحران صرعی حدود ۳۴۰/۱۰۰۰۰۰ در سال است. همچنین، سالانه تعداد بیماران مبتلا به بحران صرعی که نیاز به مراقبت‌های بیمارستانی و ویژه دارند ۲۰/۱۰۰۰۰۰ است و این خطر بیشتر در کمین کودکان و سالمندان است. عواملی که اغلب باعث ایجاد بحران صرعی در بزرگسالان می‌شود؛ عبارت اند از: تعادل ضعیف در درمان صرع، بیماری‌های عصبی تشخیص داده شده پیشین و علایم حادی مانند حمله ایسکمیک گذرا (سکته مغزی گذرا) یا حمله آریتمی شدید قلبی (ضربان نامنظم قلبی). برای کودکان شایع ترین علل تب، بیماری‌های عصبی تشخیص داده شده پیشین و عفونت در

⁸ Status Epilepticus

سیستم عصبی مرکزی است. سالانه در بخش‌های مراقبت‌های ویژه فنلاند به طور میانگین ، ۳.۴/۱۰۰۰۰۰ بیمار با بحران صرعی شدید و ۰.۷/۱۰۰۰۰۰ بیمار با بحران صرعی بسیار شدید تحت درمان قرار گرفتند [۲۰].

بحران صرعی یک وضعیت اورژانسی عصبی است که نیاز به درمان سریع و حتی بیهوشی عمومی برای پایان دادن به تشنج دارد. با این حال، اکثر تشنجهای صرعی کوتاه مدت هستند و بدون درمان خاصی خاتمه می‌یابند. در بحران صرعی دو بعد عملیاتی وجود دارد: اولی نقطه زمانی (t_1) که در آن تشنج باید به عنوان فعالیت تشنج مداوم در نظر گرفته شود و نقطه زمانی (t_2) که در آن خطر عواقب طولانی مدت حمله شروع به افزایش چشمگیری می‌کند. نقاط زمانی فعلی t_1 و t_2 فقط برای صرع‌های تونیک-کلونیک، کانونی با اختلال هوشیاری و بحران صرعی غایب تعریف شده است. برای سایر انواع بحران صرعی، نقاط زمانی هنوز تعریف نشده است. در دیدگاه بالینی t_1 زمان شروع درمان را تعیین می‌کند و t_2 تعیین می‌کند که چگونه درمان سریع باید برای جلوگیری از عواقب طولانی مدت اجرا شود [۱۸].

در جزئیات بیشتر، بحران صرعی در چهار بخش مختلف علائم شناسی، علت شناسی، همبستگی EEG و سن طبقه‌بندی می‌شود. بر اساس وضعیت نشانه شناسی، صرع به دو دسته عدم وجود علائم حرکتی برجسته و درجه اختلال در هوشیاری طبقه‌بندی می‌شود. بحران صرعی یک بیماری نیست؛ بلکه یک علامت است که علل مختلفی دارد. طبقه‌بندی انواع تشنج را نمی‌توان به سادگی برای طبقه‌بندی صرع بحرانی نیز اعمال کرد؛ زیرا علائم در طول صرع بحرانی ممکن است در مقایسه با تشنجهای کوتاه مدت بسیار متفاوت باشد. طبقه‌بندی صرع بحرانی بر اساس علت شناسی در شکل ۲.۲ ارائه شده است. الگوی سیگنال‌های EEG ناگهانی هر نوع بحران صرعی منحصر به فرد نیست. بنابراین، هیچ معیار EEG برای بحران صرعی وجود ندارد، اما ویژگی‌هایی مانند محل، نام الگو، ویژگی‌های مرتبط با زمان، مدولاسیون و اثر مداخله وجود دارد که الگوهای EEG را در بحران صرعی توصیف می‌کند. گروه‌های سنی مختلف بحران صرعی عبارتند از: ۱- نوزادان (۰ تا ۳۰ روز)، ۲- شیرخواران (۱ ماه تا ۲ سال)، ۳- کودکی (بیشتر از ۲ تا ۱۲ سال)، ۴- نوجوانی و بزرگسالی (بیش از ۱۲ تا ۵۹ سال)، ۵- سالمندان (بیش از ۶۰ سال) [۲۱].

بحران صرعی بر اساس شدت آن دارای چهار مرحله است: ۱- بحران صرعی اولیه، ۲- بحران صرعی ثابت، ۳- بحران صرعی مقاوم به درمان و ۴- بحران صرعی فوق مقاوم. اهداف درمان بحران صرعی شامل حفظ عملکردهای حیاتی، خاتمه سریع علائم تشنج بالینی و تخلیه الکتریکی فعالیت انحرافی مغز است. پس از مرحله حاد، مهمترین اهداف درمان پیشگیری از عود تشنج، مشاهده عوارض سیستمیک، تشخیص علل و به حداقل رساندن مرگ و میر و علائم ثانویه است.

۲.۱.۵. منشأ EEG

نوار مغزی (EEG) یک تحقیق عصبی فیزیولوژیکی به منظور اندازه‌گیری فعالیت الکتریکی سلول‌های مغز است. در ثبت EEG تفاوت پتانسیل الکتریکی بین الکترودهایی که به صورت تهاجمی یا غیرتهاجمی به پوست سر متصل می‌شوند، اندازه‌گیری می‌شود. منشأ پتانسیل‌های مغزی منعکس‌کننده خواص الکتروفیزیولوژیکی ذاتی سیستم عصبی است. EEG اساساً توسط نورون‌های هرمی قشری که در قشر مغز و عمود بر سطح مغز قرار دارند، ایجاد می‌شود. ایجاد سیگنال‌های EEG

نیاز به فعال‌سازی هم‌زمان میلیون‌ها سلول عصبی در همان ناحیه از مغز دارد. طبق نتایج تحقیقات اخیر، EEG ممکن است حاوی اجزایی از سایر ساختارهای سلولی باشد [۲۲].

EEG زمانی ایجاد می‌شود که بارهای الکتریکی در داخل قشر مغز حرکت کنند. عملکرد عصبی قشر مغز با گرادیان‌های یونی ایجاد شده توسط غشای عصبی حفظ می‌شود. جریان‌های الکتریکی فعالیت مغزی باید تقویت شده و برای تجزیه و تحلیل نمایش داده شوند. پتانسیل سیناپسی (محل اتصال دو نورون) منبع اصلی جریان خارج سلولی است که در EEG دیده می‌شود. این پتانسیل‌های سیناپسی به عنوان پتانسیل‌های تحریکی پس سیناپسی^۹ نامیده می‌شوند که به صورت درون‌گرا به سایر قسمت‌های سلول از طریق یون‌های سدیم و کلسیم جریان می‌یابند و پتانسیل‌های پس سیناپسی مهاری^{۱۰} که در عوض به صورت برون‌گرا جریان می‌یابند و یون‌های کلرید یا پتاسیم را شامل می‌شوند. EEG شواهدی از میدان‌های ولتاژ پیوسته و متغیر ارائه می‌دهد که در محل‌های مختلف روی پوست سر در طول زمان متفاوت است [۲۳].

مهمترین مقادیر اندازه‌گیری شده EEG دامنه و فرکانس است. دامنه EEG معمولاً در حدود ده‌ها تا صدها میکروولت است و اندازه فعالیت هم‌زمان گروه سلول‌های عصبی را منعکس می‌کند. فن‌آوری به کار رفته در اندازه‌گیری یک عامل مهم در EEG است، اما همچنین ضخامت، هدایت الکتریکی و اندازه پوست سر و فاصله و موقعیت الکترودها تأثیر قابل توجهی در اندازه‌گیری دارد. در EEG فرکانس به آرامی از ۱ تا چند صد هرتز تغییر می‌کند. فعالیت الکتریکی خود به خودی مغز شامل نوسانات ولتاژ در فرکانس‌های مختلف است. بر اساس تحقیقات و یافته‌های پیشین، باندهای فرکانسی به باندهای دلتا (کمتر از ۴ هرتز)، تتا (۴-۸ هرتز)، آلفا (۸-۱۳ هرتز) و بتا (بیش از ۱۳ هرتز) تقسیم می‌شوند. فعالیت سریع مغز در فرکانس حدود ۴۰ هرتز به عنوان "فعالیت گاما" نامیده می‌شود. در عمل فرکانس EEG طبیعی حدود ۰.۵ تا ۲۵ هرتز است، اما تشنج‌های صرع ممکن است باعث انفجارهای الکتریکی سریع شوند که حتی به فرکانس بیش از ۲۰۰ هرتز در سیگنال EEG می‌رسد [۲۴].

تنظیم EEG بسته به استفاده متفاوت است، بنابراین چندین نمونه EEG برای اهداف مختلف وجود دارد. تنظیم اولیه اندازه‌گیری EEG به عنوان سیستم بین‌المللی ۲۰-۱۰ نامیده می‌شود (شکل ۲.۴). تحقیقات اولیه EEG معمولی تنها شامل ۱۹ کانال (الکتروود) بود، اما در حال حاضر فدراسیون بین‌المللی نوروفیزیولوژی بالینی^{۱۱} (IFCN) توصیه جدیدی برای افزایش تعداد الکترودها به ۲۶ ارائه کرده است. تعداد بیشتر الکترودها این قابلیت را دارد که فعالیت‌های مغزی که به دلیل تعداد کم الکترودها دیده نمی‌شدند؛ را نشان دهد. بیشتر اندازه‌گیری‌های EEG در مراقبت‌های ویژه یا در اورژانس مراکز درمانی ثبت می‌شوند. تعداد الکترودها به دلیل شرایط موجود به کانال‌های مهم و ضروری مورد نیاز در مراقبت‌های ویژه و اورژانس کاهش می‌یابد. اغلب کانال‌های ضبط ویدئویی و پلی‌گراف (دستگاهی برای ثبت خودکار فشار خون، نبض و تنفس) که همگام‌سازی شده^{۱۲} اند؛ به اندازه‌گیری EEG افزوده می‌شوند. کانال‌های پلی‌گراف معمولی عبارتند از: ECG.

⁹ Excitatory Postsynaptic Potentials

¹⁰ Inhibitory Postsynaptic Potentials

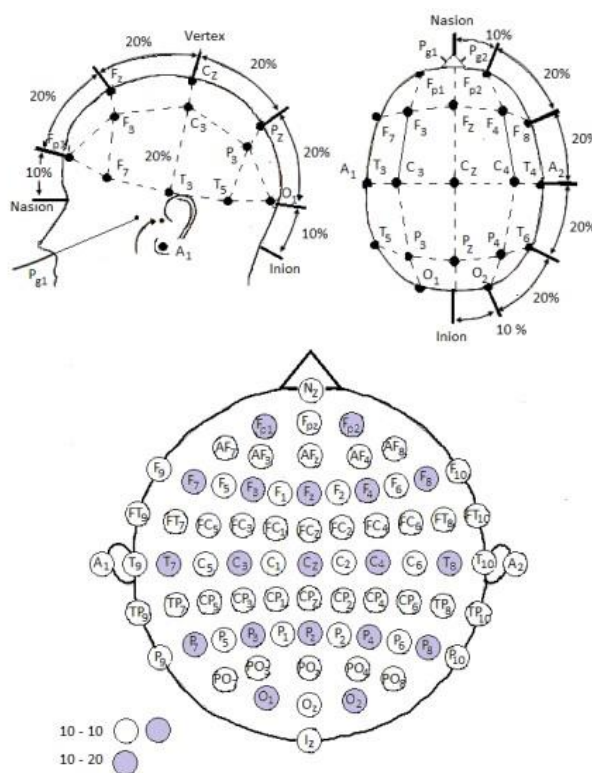
¹¹ International Federation of Clinical Neurophysiology

¹² Synchronized

EOG, EMG, تنفس اندازه گیری شده با کمر بند تنفسی^{۱۳}، اشباع اکسیژن اندازه گیری شده با پالس اکسیمتری و سیگنال های تداخل حرکتی اندازه گیری شده با سنسورهای پیزوالکتریک [۲۵].

۲.۱.۶. ثبت و فعال سازی EEG

اغلب EEG از الکترودهایی که به صورت غیرتهاجمی به پوست سر متصل هستند؛ اندازه گیری می شود. نام الکترودها نشان دهنده لوب قشر مغز است که الکترودها در آن قرار می گیرند (شکل ۲.۳). الکترودها در مواد به کار رفته در آنها، شکل هندسی و نحوه اتصال آنها متفاوت هستند. الکترودها را می توان به طور جداگانه به پوست سر، با کلاه یا بافت همراه با ژل به سر متصل کرد؛ که تماس بهتری بین الکترودها و پوست را تضمین می کند. نوع الکترودها کمی بر حساسیت به تداخل، پاسخ فرکانسی و زمینه کاربرد تأثیر می گذارد. یک اتصال الکتریکی از بافت مغز به تقویت کننده از طریق الکترودها و کابل ها ایجاد می شود. تقویت کننده سیگنال های EEG را بر اساس مونتاژ انتخابی (مجموعه الکترودهایی که تکنسین برای ثبت انتخاب می کند) اندازه گیری می کند. عملکرد کانال ها باید با سیگنال کالیبراسیون در ابتدا و در پایان ثبت و در صورت لزوم در حین ثبت آزمایش شود [۲۶].



شکل ۲.۴. سیستم بین المللی ۱۰-۲۰ از (شکل سمت چپ) سمت چپ و (شکل سمت راست) بالای سر دیده می شود. A = لوب گوش، C = مرکزی، Pg = نازوفارنکس، P = جداری، F = فرونتال، Fp = قطبی فرونتال، O = اکسیپیتال [۲۶].

قسمت های مختلف EEG دارای آرایش استاندارد و انتخاب زنجیره و جفت های کانال برای نمایش و بررسی است. مونتاژها به دو دسته تقسیم می شوند: ۱- دوقطبی و ۲- ارجاعی-تک قطبی. در مونتاژ دوقطبی، یک الکترود به یک یا دو الکترود مجاور متصل می شود و زنجیره ای از الکترودها را تشکیل می دهد. الگوی طولی دوقطبی رایج ترین مونتاژ دوقطبی است. در الگوی طولی هر کانال، الکترودهای مجاور را از جلویی به عقبی در دو خط به هم متصل می کند (شکل ۲.۴). مونتاژ متقاطع دوقطبی، الکترودهای مجاور را در یک زنجیره از چپ به راست به هم متصل می کند. در مونتاژ تک قطبی هر الکترود به یک نقطه مرجع متصل است. نقطه ارجاعی مونتاژ تک قطبی می تواند رأس، فرآیند ماستوئید یا مرجع متوسط معمولی^{۱۴} باشد. الکترود Cz رأس را نشان می دهد و فرآیند ماستوئید شامل الکترودهایی از هر دو گوش یا یک مشتق ریاضی از هر دو طرف است. یکی دیگر از مونتاژهای رایج در ارزیابی صرع، مونتاژ لاپلاسین است. لاپلاسین^{۱۵} به معنای منبعی برای استخراج و بدست آوردن مونتاژ است که در آن هر الکترود با میانگین وزنی الکترودهای همسایه مقایسه می شود [۱۸].

انواع مختلفی از فعال سازی ها در طول ثبت EEG برای به دست آوردن اطلاعات مفیدی در مورد عملکرد شبکه عصبی استفاده می شود. فعال سازی روتین همان فعال سازی چشمان باز - چشمان بسته است. در معاینه ی صرع، هایپرونتیلیسیون و تحریک نور چشمک زن، فعال سازی های کلیدی برای تحریک فعالیت صرعی هستند. در طول تست هایپرونتیلیسیون، بیمار ۳ تا ۵ دقیقه نفس عمیق می کشد و باعث کاهش غلظت دی اکسید کربن در خون می شود. غلظت دی اکسید کربن یک مشخصه ی تنظیم کننده اولیه برای سیستم عروقی مغز است. در تحریک نور چشمک زن، بیمار در معرض نور چشمک زن با فرکانس های مختلف است؛ در حالی که چشمان بیمار به طور متناوب باز و بسته می شود. محرومیت از خواب نیز برای تحریک فعالیت صرعی استفاده می شود. در کم خوابی، قبل از ثبت EEG به بیمار دستور داده می شود که شب ها نخوابد. کم خوابی باعث خواب عمیق است، از این رو از بیماران درخواست می شود که در طول شب بیدار بمانند تا کیفیت خواب بهتر در طول ثبت EEG تضمین شود [۲۷].

۲.۱.۷ EEG در تشخیص صرع و بحران صرعی

اندازه گیری EEG، ابزار بالینی اولیه برای تشخیص صرع و بحران صرعی است. EEG برای شناسایی عصبی فیزیولوژیکی، طبقه بندی، کمی سازی و محلی سازی ترشحات صرعی^{۱۶} (EDs) استفاده می شود. در جزئیات بیشتر، EEG برای نشان دادن وجود یافته ای که با صرع مرتبط است، نیز استفاده می شود، که کدام نوع صرع مورد بحث است؟ و تشنج صرعی کانونی یا عمومی است؟. همچنین، EEG برای تعیین تعداد و مدت ناهنجاری های صرعی استفاده می شود. صرع یک اختلال عملکرد الکتریکی مغز است و از این رو EEG مناسب ترین روش تحقیق برای ارزیابی فعالیت الکتریکی مغز است. امکان نظارت بر فعالیت الکتریکی - دینامیکی مغز برای ارزیابی قبل از جراحی، در نظر گرفتن توقف درمان^{۱۷} AED،

¹⁴ Common Average Reference

¹⁵ Laplacian

¹⁶ Localization of Epileptiform Discharges

¹⁷ Automated External Defibrillator

(دستگاه شوک خودکار در حملات قلبی) نظارت بر دفعات تشنج، نظارت بر اثر دارو و تصمیم گیری در مورد اینکه آیا بیمار گواهینامه رانندگی یا گواهی پرواز داشته باشد، ضروری است [۲۸].

در یافته‌های اولیه EEG که با صرع مرتبط است، تنها در ۵۰ درصد از بیماران، صرع در اولین ثبت یافت می‌شود. با تکرار ثبت EEG همراه با کمبود خواب، ۸۰ تا ۹۰ درصد یافته‌های صرع کشف می‌شود. در ۱٪ از جمعیت می‌توان ویژگی‌های فعالیت صرعی را در نوار مغزی بدون صرع مشاهده کرد. EEG سرپایی امکان نظارت بر فعالیت الکتریکی مغز در محیط خانه‌ی بیمار را برای ثبت فراهم می‌کند. از مزایای نوار مغزی سرپایی می‌توان به تعیین تعداد و طول مدت تشنج‌های بالینی و تشنج‌های بدون آگاهی اشاره نمود. در برخی موارد، تشنج کانونی صرعی به سختی قابل شناسایی است. استفاده از مانیتورینگ EEG تهاجمی با الکترودهای داخل جمجمه (ECOG¹⁸) در صورتی ضروری است که محل شروع تشنج با ارزیابی قبل از جراحی غیر تهاجمی پیدا نشده باشد یا هدف، تعریف دقیق عملکرد قشر مغز در ناحیه تعیین شده برای جراحی، باشد [۲۹].

EEG مهمترین روش تحقیق در تشخیص و نظارت بر درمان وضعیت صرع است. در مورد بحران صرعی، نوار مغزی مخصوصاً برای مشکوک به بحران صرعی غیر تشنجی استفاده می‌شود. در شرایط اضطراری، EEG یک ابزار بالینی اولیه در طبقه‌بندی بحران صرعی است، با تعریف بیمار مبتلا به SE تونیک-کلونیک، SE غایب، SE کانونی یا SE روانی - حرکتی. EEG برای ارزیابی انتخاب مناسب داروی ضد صرع مورد نیاز است. بیماری که از بحران صرعی رنج می‌برد، تحت نظارت مداوم EEG است. بنابراین، EEG به تعیین اندازه دوز داروی ضد صرع و تعیین زمان پایان تشنج بحران صرعی کمک می‌کند [۳۰].

علائم تشنج بحران صرع به دلیل علائم حرکتی راحت‌تر از غیر تشنجی قابل تشخیص است. هر دو نوع نیاز به ثبت و بررسی EEG دارند. اما نوع غیر تشنجی حیاتی‌تر است؛ زیرا علائم وضعیت صرع غیر تشنجی ممکن است به وضوح قابل مشاهده نباشد. بحران صرع عمومی همیشه در سیگنال‌های EEG قابل مشاهده است، اما در برخی موارد ثبت و بررسی EEG بحران صرع کانونی، طبیعی به نظر می‌رسد. در تشنج‌های کانونی، فعالیت صرعی ممکن است در ناحیه خیلی کوچک مغز یا در بافت خیلی عمیق مغز باشد، بنابراین در سیگنال EEG قابل مشاهده نیست [۳۱].

تشخیص صرع برای افراد بدون صرع مضرتر از تشخیص ندادن صرع است؛ حتی اگر بیمار از آن رنج می‌برد. تشخیص صرع همیشه به اطلاعات بالینی دیگری علاوه بر EEG نیاز دارد، بنابراین تشخیص صرع نمی‌تواند به طور کامل بر اساس نتایج EEG باشد. در برخی موارد، ویژگی‌های صرعی بین دو تشنج^{۱۹} در EEG لزوماً همیشه نشان‌دهنده صرع نیست. تشخیص نادرست اغلب ناشی از تفسیر اشتباه EEG است، زمانی که EEG حاوی خطا است یا پزشکان نظرات مخالف دارند [۳۲].

¹⁸ Electrocorticography

¹⁹ Interictal

شرایطی مربوط به مواردی نظیر نارسایی قلبی، سمی-متابولیکی، نارسایی ریوی، اختلالات حرکتی، سردردهای میگرنی، بیماری‌های مغزی، اختلالات اتونومیک، اختلالات خواب، اختلالات دهلیزی یا فراموشی کلی گذرا ممکن است در EEG علائم تشنج صرع را نشان بدهند. همچنین، اختلالات روانپزشکی وجود دارد که ممکن است علائم تشنج‌های صرعی مانند تشنج‌های غیرصرعی روان‌زا، سوءمزاج، حمله عصبی، توهم-روان‌پریشی، اختلال در کنترل اپیزودیک، حالت فوگ و سندرم مونشهاوزن را به واسطه نیابتی تقلید کنند [۱۸].

۲.۱.۸. تفسیر EEG

تجزیه و تحلیل EEG مستلزم درک اساس EEG، فناوری ضبط، اصطلاحات توصیفی و قابلیت‌ها و محدودیت‌های عمومی است. با درک این عوامل، تفسیر و تشخیص EEG را می‌توان با وضوح بیشتری مورد توجه قرار داد و منجر به پیش‌آگهی و تشخیص مناسب شد. تفسیر EEG در مورد شناسایی الگوها و تعریف الگوهای مربوط به بیمار بسیار مهم و حیاتی است. اجزای اصلی ویژگی EEG دیدگاهی در مورد فعالیت الکتریکی مغز ارائه می‌دهند. آشنایی با ویژگی‌های مؤلفه‌ای که هر الگو را مشخص می‌کند، یک جنبه مهم در تفسیر EEG است [۳۶].

سیگنال EEG از چندین الگو شامل فعالیت ریتمیک یا دوره‌ای تشکیل شده است. شکل موج‌های EEG به باندهای فرکانسی دلتا (۰.۱-۴ هرتز)، تتا (۴-۸ هرتز)، آلفا (۸-۱۳ هرتز) و بتا (۱۴-۳۰ هرتز) تقسیم می‌شوند. همچنین، الگوی موج فرکانس بالا به نام گاما (۳۰ تا ۸۰ هرتز) می‌باشد و یک الگوی موج به نام میو وجود دارد که با سایر باندهای فرکانسی (۷ تا ۱۱ هرتز) همپوشانی دارد. شکل موج EEG بیان‌کننده فرآیندهای فیزیولوژیکی و ذهنی است. سیگنال EEG ممکن است دارای امواج ضربه‌ای^{۲۰}، گذرا و الگوهای دیگری باشد که با اختلالات مختلف سیستم عصبی مانند صرع مرتبط است [۳۷].

شناسایی و بررسی الگوهای صرعی از طریق ویژگی‌ها با دسته‌بندی بخش‌های EEG به انواع میرا، گذرا و تکراری آغاز می‌شود. الگوی میرا به عنوان ولتاژ کم یا کاهش قابل توجه در دامنه تعریف می‌شود. این الگوها بر اساس توزیع فقط به انواع کانونی، نیمکره‌ای، دوطرفه یا عمومی طبقه‌بندی می‌شوند. توزیع‌ها بر اساس مکان‌های دقیق‌تر در مغز دارای عناوین فرعی نظیر پیشانی، گیجگاهی، آهیانه^{۲۱}، مرکزی، پس‌سری^{۲۲} هستند. الگوی گذرا به عنوان یک موج مجزا یا پیچیده تعریف می‌شود و ابتدا بر اساس توزیع طبقه‌بندی شده و با مکان(ها) مشخص می‌شود. الگوی گذرا بیشتر به تک فازی، دو فازی و سه فازی و اینکه آیا موج ضربه‌ای، تیز و یا آهسته هستند، دسته‌بندی می‌شوند. در نهایت، الگوی گذرا با قطبیت مشخص می‌شود. الگوی تکرار به معنای یک الگوی گذرای مکرر است و همچنین، بر اساس توزیع و اینکه آیا گذرای تکرار شونده تک فازی یا چند فازی است، دسته‌بندی می‌شوند. این الگو با مکان(ها) و منظم یا در حال تکامل بودن الگو مشخص می‌شوند [۳۸].

²⁰ Spike

²¹ Parietal

²² Occipital

شرایط فیزیولوژیکی و روانی مختلفی وجود دارد که ممکن است الگوهای EEG مشابهی نسبت به ترشحات صرعی داشته باشند. این شرایط فیزیولوژیکی و روانی در بخش "EEG در تشخیص صرع و بحران صرعی" [۱۸] ذکر شده است. همچنین، عوامل فیزیولوژیکی و غیرفیزیولوژیکی وجود دارد که ممکن است علائمی نظیر ترشحات صرعی را در EEG داشته باشد. این عوامل باید در تفسیر EEG نیز در نظر گرفته شوند [۱۸].

شناسایی الگوهای صرعی بر اساس ایجاد معیارهایی برای فعالیت EEG طبیعی است. ارائه اطلاعاتی در مورد تغییرات شکل موج طبیعی برای هر گروه سنی در طول چرخه زندگی از نوزادی تا سالمندی ضروری است. همان طور که قبلاً ذکر شد، امواج مغزی را می‌توان به دلتا، تتا، آلفا، بتا و همچنین باندهای میو و گاما تقسیم کرد. باندهای فرکانسی مختلف و روابط فیزیولوژیکی آن‌ها در جدول ۲.۱ ارائه شده است. EEG طبیعی در بزرگسالان شامل فعالیت‌های آلفا و بتا است؛ همچنین شامل فرکانس‌های موج دیگری در بازه‌ی ۷۰-۵۰ هرتز است. امواج در ریتم‌هایی مشخص یا به طور خود به خود و جداگانه ایجاد می‌شوند، جایی که امواج فرکانس‌های مختلف با هم مخلوط می‌شوند. EEG دائماً پویا (دینامیکی) است و همراه با وضعیت فیزیولوژی تغییر می‌کند. در نتیجه، می‌توان از EEG دریافت که فرد بیدار، در خواب سبک، در خواب، عصبی، دارای چشمان باز، دارای چشمان بسته و غیره است. تنها با ایجاد ارتباط بین EEG و وضعیت بیمار می‌توان گفت که الگوهای ثبت‌شده در EEG طبیعی یا غیر طبیعی است. EEG بین افراد متفاوت است؛ اما برای یک فرد EEG بین ضبط‌های جداگانه تقریباً مشابه است که این حالت هم با گذر عمر تغییر می‌کند [۱۸].

ریتم آلفا به عنوان یک حالت آماده به کار فعال یک الگوی عادی است که به سطوح دروازه‌ای ۲۳ توجه بصری مربوط می‌شود. ریتم آلفا شامل فعالیت غالب است؛ در حالی که بیمار از نظر ذهنی و جسمی آرام است لیکن در خواب سبک نیست. در بزرگسالان بیدار و در حال استراحت، به ویژه در ناحیه پس سری شایع است. ریتم آلفا هنگام باز کردن چشم‌ها ضعیف می‌شود، اما افراد مختلف دارای واکنش‌های متفاوتی هستند. فرکانس ریتم آلفا در ۷۰ درصد افراد ۲۰ ساله ۹ تا ۱۱ هرتز است. از هر صد نفر، یک نفر دارای ریتم آلفای آهسته ۴-۵ هرتز در قسمت پشت سر است. ریتم نوع آلفای سریع که در فرکانس‌های ۱۴ تا ۲۰ هرتز اتفاق می‌افتد، از ریتم نوع آلفای آهسته نادرتر است. ریتم‌های گوناگون آلفا مانند ریتم آلفا به محرک‌های خارجی واکنش نشان می‌دهند. بیش از نیمی از بزرگسالان دارای ریتم آلفا با دامنه بین ۲۰-۵۰ میکروولت هستند. ۱۰٪ از بزرگسالان کمتر از ۲۰ میکروولت دارند و در موارد نادرتر، دامنه ریتم آلفا بیش از ۱۰۰ میکروولت است. ریتم آلفا معمولاً در نواحی پس سری و گیجگاهی پسی رخ می‌دهد. گاهی اوقات ریتم آلفا نیز در نواحی گیجگاهی پیشی، مرکزی و حتی در چند الکتروود در ناحیه پیشانی به طور ضعیف ظاهر می‌شود [۱۸].

ریتم آلفا با ریتم‌های آهسته‌تر در مراحل مختلف خواب جایگزین می‌شود. ریتم تتا دارای محدوده فرکانسی از ۴ هرتز تا ۷ هرتز می‌باشد. امواج تتا در کودکان در ناحیه وسیعی از بخش مرکزی گیجگاه مغز رایج است. این ریتم ممکن است در بزرگسالان بدون اختلال، در مراحل اولیه خواب یا در هنگام برانگیختگی^{۲۴} ظاهر شود. وجود امواج تتا در بزرگسالان بیدار نشان دهنده یک نوع ناهنجاری است. فعالیت تتا در فرکانس‌های ۶-۷ هرتز برای یک سوم از بزرگسالان رده سنی جوان

²³ Gated Levels

²⁴ Arousal

در نواحی مرکزی پیشانی کاهش می‌یابد. فعالیت تتا در طول اجرای وظایف فعال‌سازی ذهنی برجسته‌تر است، اما به دلیل تضعیف ریتم‌های موجود در خواب سبک، می‌توان آن را با وضوح بیشتری مشاهده کرد. فعالیت تتا به صورت چند شکلی دوطرفه یا عمومی شواهدی از خواب آلودگی طبیعی یا اختلالات مغزی در بزرگسالان است. اما در نوزادان، وقوع فعالیت تتا طبیعی است [۳۹].

ریتم دلتا محدوده فرکانسی از ۰.۵ هرتز تا ۴ هرتز است. در مقایسه با سایر باندهای فرکانسی EEG، بالاترین دامنه و کندترین امواج را داراست. امواج دلتا در مراحل خواب عمیق در بزرگسالان بدون اختلال ظاهر می‌شوند. فعالیت طبیعی دلتای چند شکلی نشانه به خواب رفتن آرام چشم است. فراوانی فعالیت دلتای چندشکلی با پیشرفت خواب به مراحل خواب عمیق‌تر کاهش می‌یابد. فعالیت دلتای چند شکلی بسته به ویژگی‌ها و شرایط آن یافته ممکن است طبیعی یا غیر طبیعی باشد. فعالیت غیر طبیعی دلتای چند شکلی ممکن است نشان دهنده بیماری مغزی^{۲۵} باشد [۴۰].

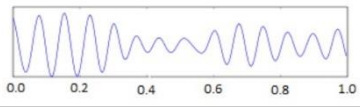
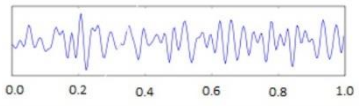
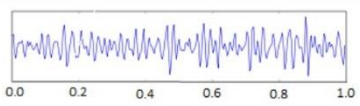
ریتم بتا با فرکانس بالا (۱۴ هرتز تا ۳۰ هرتز) بیشتر نشانه خواب آلودگی یا شروع خواب هستند، اما در برخی افراد در حالت بیداری کامل وجود دارد. این موج به ندرت با اضطراب و هوشیاری همراه است. اکثر فعالیت بتا که در EEG در بزرگسالان مشاهده می‌شود؛ در فرکانس‌های ۱۸-۲۵ هرتز رخ می‌دهد. ریتم‌هایی در بازه فرکانسی ۱۴-۱۶ هرتز و بیش از ۳۵ هرتز کمتر رایج هستند. فعالیت بتا دامنه‌ای کمتر از ۲۰ میکروولت دارد. فعالیت بتا بیشتر در نواحی پیشانی، مرکزی و گاهی در نواحی پس‌سری قابل مشاهده است. واکنش بتا در نواحی پس‌سری به محرک درست مانند ریتم آلفا و بتا مرکزی به عنوان ریتم میو است. ریتم میو هنگام آمادگی برای حرکت یا در حین حرکت ضعیف می‌شود و در الکترودهای C3 و C4 قابل مشاهده است. فعالیت بتا بر روی عملکرد شناختی، در خواب سبک و در خواب REM^{۲۶} تأکید می‌کند [۴۱].

جدول ۲.۱. توصیف فرکانسی امواج مغزی.

شکل موج نمونه	رفتارهای فیزیکی	باند فرکانسی (هرتز Hz)	امواج مغزی
	حالت خواب عمیق، خواب عمیق، از دست دادن هوشیاری بدنی	۰.۵ - ۴	دلتا
	حالت هیپنوتیدی، کاهش هوشیاری، مدیتیشن عمیق، رویاها، خواب سبک، خواب REM	۴ - ۸	تتا
	حالت استراحت طبیعی، از نظر جسمی و ذهنی مرتبط، بیدار اما خواب‌آلود	۸ - ۱۳	آلفا


²⁵ Encephalopathy

²⁶ Rapid Eye Movement

میو	۸ - ۱۴	نشانه‌گر فعال شدن نورون‌های حرکتی در حالت استراحت	
بتا	۱۴ - ۳۰	حالت بیداری طبیعی، بیدار، هوشیاری عادی	
گاما	۳۰ - ۱۰۰	ادراک افزایش یافته	

۲.۱.۹. EEG در مقابل ECOG

الکتروانسفالوگرام (EEG) نشان دهنده فعالیت کلی مغز است. این فعالیت با استفاده از جفت الکترودهایی که بر روی سطح پوست سر قرار دارند ضبط میشود. در نوروفیزیولوژی بالینی، الکترودها مطابق با استاندارد بین المللی سیستم (۱۰-۲۰) و یا نسخه پیشرفته آن، سیستم ۱۰-۱۰ قرار می‌گیرند. در موارد خاص، فعالیت مغز می‌تواند به طور مستقیم از طریق الکترودها روی سطح قشر (الکتروکورتیکوگرافی، ECoG، شکل ۲.۵) و یا از طریق الکترودهای عمیق (ایمپلنت‌های مغزی LFP) کاشته شده در مغز اندازه‌گیری شود. هر دو EEG از سطح پوست سر یا سیگنال‌های داخل جمجمه برای الگوهای به اصطلاح پیش‌زمینه (به عنوان مثال، اسپایک صرعی) و فعالیت پس‌زمینه ارزیابی می‌شوند. فعالیت‌های پس زمینه معمولاً توسط قدرت سیگنال در درون باند فرکانسی‌های مختلف مشخص می‌شود [۴۳].



شکل ۲.۵. انواع ضبط سیگنال مغزی [۴۳].

۲.۱.۱۰. ناهنجاری های صرعی

ناهنجاری های صرعی به عنوان عوامل گذرا قابل تشخیص از فعالیت موجود در سیگنال EEG دیده می شوند. اصطلاح صرعی به عنوان یک الگوی EEG تعریف می شود که با خطر نسبتاً بالایی برای داشتن تشنج همراه است. شش معیار در رابطه با مورفولوژی مشخصه الگوهای صرعی وجود دارد که برای تعریف یک الگوی خاص به عنوان الگوی صرعی باید ۴ مورد از آنها رعایت شود:

۱. امواج دو یا سه فاز با مورفولوژی تیز یا ضربه ای (یعنی دارای قله نوک تیز).
۲. طول موج متفاوت با طول موج فعالیت موجود، حال کوتاه تر یا طولانی تر.
۳. عدم تقارن شکل موج: یک فاز صعودی به شدت در حال افزایش و یک فاز نزولی با میرایی آهسته تر، یا بالعکس.
۴. گذرا همراه با یک پس موج آهسته.
۵. فعالیت موجود اطراف ترشحات صرعی با حضور ترشحات صرعی توزیع می شود.
۶. توزیع پتانسیل های منفی و مثبت روی پوست سر نشان دهنده منبع سیگنال در مغز است؛ که مطابق با جهت شعاعی، مایل یا مماس بر منبع است. این به بهترین وجه با بررسی الگوهای ولتاژی ساخته شده با استفاده از مرجع میانگین مشترک ارزیابی می شود [۱۸].

بر اساس توضیحات آقای و کوری و همکاران دلتای ضربه ای^{۲۷} (DSP)، ریتمیک چند ضربه ای^{۲۸} (PSR)، ترشحات دوره ای صرعی^{۲۹} (PED)، و مهار ضربه ای^{۳۰} (SSP) به عنوان الگوهای صرعی در نظر گرفته می شوند. این الگوهای صرعی معمولی را در سیگنال های EEG نشان می دهد. DSP شامل فعالیت دلتا با هر فرکانس با ضربه های منظم یا نامنظم است. PSR شکل موج هایی با بیش از دو انحراف منفی و مثبت هستند؛ که در فواصل منظم ظاهر می شوند و با فعالیت EEG امواج آهسته یا فرکانس مختلط ضربه های گروهی مرتبط هستند. SSP به معنای قسمت های کوتاهی است که عمدتاً شامل یک ضربه منفرد است که در طول مهار کامل EEG ظاهر می شود [۱۸].

هر یک از این الگوهای صرعی از ترکیبات مختلفی از ضربه ها، امواج تیز، چند ضربه یا الگوهای موج آهسته تشکیل شده است. امواج تیز و ضربه ها از نظر مدت زمان متفاوت هستند (۲۰۰-۷۰ میلی ثانیه در مقابل کمتر از ۷۰ میلی ثانیه)، اما در عمل یک چیز مشابه را بیان می کنند. Polyspikes ها چند ضربه هستند که معمولاً به صورت متوالی و سریع مشاهده می شوند (معمولاً در فرکانس های ۱۰ هرتز یا سریعتر). گروهی متشکل از ضربه و موج آهسته مربوط به پدیده ای است که

²⁷ Delta with Spikes


²⁸ Rhythmic Polyspikes

²⁹ Periodic Epileptiform Discharges

³⁰ Suppression with Spikes

در آن یک ضربه فوراً توسط یک موج آهسته ادامه می‌یابد. گروه شامل چند ضربه و موج آهسته شبیه گروه تک ضربه و موج آهسته است، اما با چند ضربه و یک یا چند موج آهسته همراه است [۱۸].

یک الگوی EEG صرعی به حالت‌های پریکتال^{۳۱}، ایکتال^{۳۲}، اینتریکتال^{۳۳} و پستیکتال^{۳۴} تقسیم می‌شود (شکل ۲.۶). حالت پریکتال به معنای دوره‌ای در EEG قبل از وقوع تشنج است. حالت پریکتال اغلب شامل علائم ملایمی در برخی از انواع صرع است، اما گاهی اوقات بدون هیچ علامتی ظاهر می‌شود. شواهدی وجود دارد که می‌تواند تشنج صرعی را پیش از وقوع آن پیش‌بینی کند. تشخیص حالت پریکتال از EEG حوزه بسیار جالبی در تحقیقات صرع بوده است. سیر تکاملی الکتروگرافی تشنج معمولاً شامل یک یا چند ویژگی است؛ که شامل تغییر در فرکانس، دامنه، توزیع و یا شکل موج می‌باشد. این ویژگی‌ها حداقل پنج الگوی EEG رایج در شروع تشنج را تشکیل می‌دهند: تکامل ریتمیک در فرکانس‌های تتا، دلتا و آلفا، ضربه‌ی ریتمیک، امواج ضربه‌ای یا الکتروکاهشی^{۳۵}. در برخی موارد، تغییر واضحی در EEG وجود ندارد [۴۲].



شکل ۲.۶. مراحل تشنج.

الگوی EEG ایکتال که به عنوان الگوی تشنج نیز نامیده می‌شود به عنوان یافته‌های EEG که در طول تشنج وجود دارند؛ تعریف می‌شود. الگوی ایکتال شامل ترشحات EEG صرعی مکرر در کمتر از ۲ ثانیه و یا مشخصه‌ای با تغییر تدریجی در فرکانس، دامنه، مورفولوژی و محل است که حداقل چندین ثانیه (معمولاً بیش از ۱۰ ثانیه) طول می‌کشد. الگوی ایکتال معمولاً شامل ریتم‌ها یا امواج تیز تکراری بدون توجه به نوع تشنج است. دو نوع الگوی ایکتال وجود دارد: ۱- الگوهای ایکتال برای تشنج‌های کانونی و ۲- الگوهای ایکتال برای تشنج‌های منتشر [۱۸].

یک حمله کانونی دارای ویژگی‌های مربوط به فرکانس، دامنه، توزیع و شکل موج است. فرکانس الگوی EEG در طول یک شروع کانونی ممکن است چندین هرتز در هر یک از باندهای فرکانسی طبیعی EEG، افزایش یا کاهش یابد. دامنه معمولاً افزایش می‌یابد، اما اغلب در ابتدای تشنج کاهش می‌یابد؛ زیرا دامنه به حداکثر خود رسیده است. توزیع سیر تکاملی نشان دهنده گسترش آناتومیک یا تشنج در سراسر نیمکره مغز است. ریتم ایکتال تشنج با حمله کانونی ممکن است منجر

³¹ Preictal

³² Ictal

³³ Interictal

³⁴ Postictal

³⁵ Electro Decremental

به توزیع عمومی شود. در طول تعمیم^{۳۶}، الگوی ایکتال دارای ویژگی‌های فعالیت تشنج سریع با حمله عمومی است. تشنجهایی با حمله عمومی در الگوی EEG ایکتال و اینترکتال خود الگوی مشابهی نسبت به تشنجهای با حمله کانونی دارند.

تشنجهایی با حمله عمومی را می‌توان با یکی از سه نوع مقابل مشخص کرد: ۱- فعالیت سریع حمله‌ای عمومی (GPFA)^{۳۷}، ۲- ضربه‌های عمومی^{۳۸} و ۳- گروه‌های موج آهسته عمومی (GSW)^{۳۹} یا کاهش الکتریکی. GPFA با دامنه کم و فعالیت فرکانس سریع شروع می‌شود؛ که اغلب منجر به کندی و تضعیف پستکتال می‌شود. GPFA با افزایش دامنه و کاهش فرکانس ادامه می‌یابد. گروه GSW معمولاً سه فازی با یک ضربه‌ی شروع منفی و موج آهسته‌ای که در بخش منفی تکمیل می‌شود، است. در برخی موارد GSW ممکن است به دلیل شروع چند ضربه‌ای به صورت چند فازی ظاهر شود. GSW به طور مکرر با مدت زمان حداقل ۳ تا ۵ ثانیه رخ می‌دهد. حمله عمومی ممکن است به شکل الگوی الکتروکاهشی نیز باشد؛ که به معنای تضعیف ناگهانی و عمومی است. در کاهش الکتریکی ۲۰ تا ۴۰ هرتز فعالیت ولتاژ پایین با افزایش تدریجی دامنه و کاهش فرکانس طی چند ثانیه بعدی رخ می‌دهد. کاهش الکترومغناطیسی معمولاً به GPFA تبدیل می‌شود؛ که شکل موج مشابهی دارد. تشنج با حمله عمومی معمولاً به صورت قطع ناگهانی بدون کامل شدن شکل موج و فرکانس، با تکمیل شکل موج و فرکانس، یا با از هم پاشیدگی الگوی ایکتال به پایان می‌رسد.

الگوی اینترکتال به معنای نتایج EEG بین تشنج است. در طول یک وضعیت اینترکتال، بیمار ممکن است اختلالات عاطفی داشته باشد. ترشحات صرعی اینترکتال امواج تیز، ضربه‌ها و چند ضربه‌ها هستند؛ که اغلب با امواج آهسته دنبال می‌شوند. غالباً مرزهای حالت‌های مختلف نامشخص و دلخواه هستند. برای بسیاری از ترشحات صرعی، مرز اینترکتال-کتال تار است. بخصوص، تمایز بین IED های تعمیم یافته ایکتال و بین ریکتال دشوار است؛ زیرا اغلب تنها تفاوت در شکل موج مدت زمان آن‌ها است [۴۴].

تخلیه‌های صرعی اینترکتال کانونی^{۴۰} (IEDs) دارای چهار ویژگی و مشخصه هستند: ۱- یک جزء به شدت مقابله شده^{۴۱}، ۲- الکترونگاتیوی روی سطح مغز، ۳- اختلال در فعالیت موجود اطراف، و ۴- میدانی که فراتر از یک الکتروود گسترش می‌یابد. این ویژگی‌ها همیشه در زمان IED ظاهر نمی‌شوند و همه این ویژگی‌ها صرعی نیستند، اما با هم یک چارچوب مفید برای در نظر گرفتن شکل موج IED هستند. IED ها نشانه صرع هستند، اما عاری از خطا نیستند. IED در درصد کمی از افراد در جمعیت سالم وجود دارد (۰٪ تا ۲.۶٪) [۴۵].

ترشحات صرعی اینترکتال عمومی دقیقاً در کل نیمکره تشکیل نمی‌شوند. IED های عمومی معمولاً در ناحیه میانی پیشانی ظاهر می‌شوند و به کل ناحیه پیشانی و برخی تا ناحیه قشر مخی^{۴۲} گسترش می‌یابند. IED های عمومی اغلب به

³⁶ Generalization

³⁷ Generalized Paroxysmal Fast Activity

³⁸ Generalized Spikes

³⁹ Generalized Slow-Wave Complexes

⁴⁰ Focal interictal Epileptiform Discharges

⁴¹ Countered Component

⁴² Cerebral

صورت ضربه‌ای و امواج تیز با امواج آهسته متوالی یا به صورت تنش‌های پی در پی ایجاد می‌شوند. شکل موج IED های تعمیم یافته تفاوت چندانی با شکل موج IED های کانونی ندارد. IED های عمومی نشانگر سندرم‌های صرع عمومی هستند و معمولاً در تمام اشکال صرع عمومی رخ می‌دهند [۴۶].

فعالیت سریع حمله‌ای^{۴۳} (PFA) یک الگوی صرعی است که یک نوع خاصی از فعالیت دامنه فرکانس بتا انفجاری است. فعالیت سریع حمله‌ای ممکن است به صورت ترشحات صرعی کانونی یا عمومی رخ دهد. فعالیت سریع حمله‌ای نیز بسته به مدت آن می‌تواند ناهنجاری اینتریکتال یا ایکتال باشد. PFA با یک ریتم سریع، منظم یا نامنظم آغاز می‌شود که دامنه آن معمولاً بیشتر یا گاهی کمتر از فعالیت موجود است. تغییر ناگهانی دامنه و وجود یک ریتم فرکانس بتا از ویژگی‌های کلیدی PFA است. شکل موج PFA شامل تکرار امواج تک فازی با خطوط تیز است که در فرکانس بالا ایجاد می‌شود.

ترشحات صرعی دوره‌ای^{۴۴} (PEDs) سه فازی با یک موج کانتوری تیز و در پی آن یک موج آهسته است که دارای سه نوع می‌باشد: ۱- ترشحات صرعی جانبی دوره‌ای، ۲- ترشحات صرعی دوره‌ای مستقل دو طرفه و ۳- ترشحات صرعی دوره‌ای دو طرفه. ترشحات صرعی جانبی دوره‌ای^{۴۵} (PLED) با تمرکز تنها در هر محل الکتروود پوست سر رخ می‌دهد. ترشحات صرعی دوره‌ای دوطرفه^{۴۶} (BiPEDs) ترشحات صرعی دوره‌ای متقارن و همزمان هستند. هنگامی که PLED ها دارای ظاهر ناهمزمان و نامشابه باشند، به آنها PLED مستقل دوطرفه (BIPLD) گفته می‌شود. در BIPLD، ترشحات در بیش از یک مکان در نیمکره مغز رخ می‌دهد.

الگوی پستیکتال به عنوان یک دوره بهبودی پس از تشنج صرع تعریف می‌شود. تمایز بین EEG ایکتال و پستیکتال را می‌توان بر اساس میزان (نرخ) یا مکان طبقه‌بندی کرد. پستیکتال معمولاً در محدوده فرکانس دلتا در EEG تحت عنوان تضعیف یا کاهش دیده می‌شود. در برخی موارد، بیمار در دوران نقاهت به خواب می‌رود. پستیکتال معمولاً شامل اختلالات شناختی، نقص حرکتی و حس‌ی کانونی، سردرد و میگرن پستیکتال و اتوماسیون پستیکتالی است. حالت پستیکتال اغلب شامل افسردگی یا به ندرت حتی روان پریشی می‌باشد.

الگوهای صرعی از ویژگی‌های صرع هستند، اما ظهور آنها در نوار مغزی همیشه به این معنی نیست که بیمار مبتلا به صرع است. در کنار الگوی صرعی واضح، الگوهای به اصطلاح نرمال نیز وجود دارد؛ که در شرایط خاص ممکن است نشانه‌ای از صرع نیز باشد. حالات گذرای خوش خیم صرعی خواب^{۴۷} (BETS) الگوهای EEG طبیعی هستند؛ که معمولاً در خواب سبک رخ می‌دهند. اگرچه در برخی از مطالعات شواهدی را نشان داده‌اند که بیان می‌کند افراد مبتلا به صرع نسبت به افراد بدون صرع، نرخ BETS بیشتری دارند. علاوه بر این، ضربه‌های سوزنی ممکن است ارتباط غیرمستقیم با صرع نیز داشته باشند. مهار انفجار که به طور کلی با کما و بیهوشی همراه است. در حوزه‌ی صرع، الگوی مهار انفجار نشان‌دهنده مرحله پایانی بحران صرعی یا بیهوشی‌های صرعی شدید دوران نوزادی است. یک حالت گذرا با محلی‌سازی راس به نام

⁴³ Paroxysmal Fast Activity

⁴⁴ Periodic Epileptiform Discharges

⁴⁵ Periodic Lateralized Epileptiform Discharges

⁴⁶ Bilateral Periodic Epileptiform Discharges

⁴⁷ Benign Epileptiform Transients of Sleep

گروه‌های K با شکل موج ضربه‌ای ممکن است در هنگام برانگیختگی از خواب NREM^{۴۸} در صرع های عمومی یا صرع های کانونی رخ دهد [۴۷].

۲.۱.۱۱. مصنوعات EEG^{۴۹}

تجزیه و تحلیل و تفسیر EEG اغلب با وجود انواع مصنوعات پیچیده می‌شود. مصنوعات EEG در سیگنال EEG به صورت تغییرات ولتاژی که از منبعی غیر از مغز منشأ می‌گیرد، دیده می‌شوند. مصنوع EEG به عنوان یک تفاوت پتانسیل فیزیولوژیکی به دلیل منابع اضافی مغزی موجود در ضبط‌های EEG یا تغییر EEG ناشی از عوامل غیربیولوژیکی اضافی مغزی تعریف می‌شود. قبل از انجام آنالیز، شناخت مصنوعات فیزیولوژیکی و غیربیولوژیکی، شناسایی منبع و منشأ مصنوعات و به ویژه حذف غیرفیزیولوژیکی غیرضروری از EEG بسیار مهم و حیاتی است. منابع نویز در EEG می‌تواند فیزیولوژیکی، یا ناشی از ابزار مورد استفاده یا محیط آزمایش باشد. هر نوع ضبط EEG منجر به آلودگی مصنوعات می‌شود. حذف تمام نویزها از EEG غیرممکن است؛ زیرا شناسایی برخی از منابع نویز بسیار دشوار است [۴۸]. علاوه بر حذف، ظاهر مصنوعات در سیگنال EEG نیز می‌تواند با تضعیف یا محافظت در برابر سیگنال‌های مزاحم کاهش یابد.

مصنوعات فیزیولوژیکی شامل مصنوعات قلبی، نبض، تنفسی، عروقی، حرکت چشم، عضله و مصنوعات حرکتی است. متداول‌ترین مصنوعات در طول ثبت EEG حرکات چشم، حرکات زبان، صحبت کردن، جویدن، سایر حرکات بدن و مصنوعات عروقی هستند. متداول‌ترین مصنوعات غیربیولوژیکی، مصنوعات الکترودی هستند که شامل پاپ الکترو، تماس الکترو، حرکت^{۵۰}، تعریق و پل نمکی است. مصنوعات ممکن است بر الگوی تشنج تأثیر منفی بگذارند و بنابراین؛ به طور قابل توجهی بر شناسایی تشنج صرع تأثیر می‌گذارند. سه مصنوع بسیار حیاتی عبارتند از: ۱- مصنوعات ماهیچه‌ای، ۲- حرکات چشم / پلک زدن و ۳- نویز سفید [۴۹].

برخی از مصنوعات مانند ED ها (اختلالات رفتاری) رفتار می‌کنند و بنابراین ممکن است به اشتباه به عنوان الگوی صرعی تعبیر شوند. منابع قلبی، منابع میوزنیک (مولد رشته های عضلانی و عضلات)، حرکات بدن و چشم ممکن است منجر به مصنوعاتی شوند که ناهنجاری در EEG را نمایش می‌دهند. مصنوعات تک الکتریکی ممکن است رفتار موج و امواج را تقلید کنند. به عنوان مثال، پلک زدن عمودی چشم ممکن است به عنوان یک موج تیز در EEG تفسیر شود. تشخیص نادرست مصنوع به عنوان ED می‌تواند بر درمان تأثیر منفی بگذارد و منجر به تشخیص اشتباه شود. حذف نویز سیگنال EEG قبل از تفسیر و تجزیه و تحلیل یک اولویت چالشی است. فیلترهای دیجیتال و دستکاری مونتاژ برای تشخیص آنچه در مصنوعات وجود دارد، استفاده می‌شود. استفاده از پلی‌گراف برای تشخیص مصنوعات و منابع آن‌ها مفید است [۵۰].

⁴⁸ Non-Rapid Eye Movement Sleep

⁴⁹ Artifacts

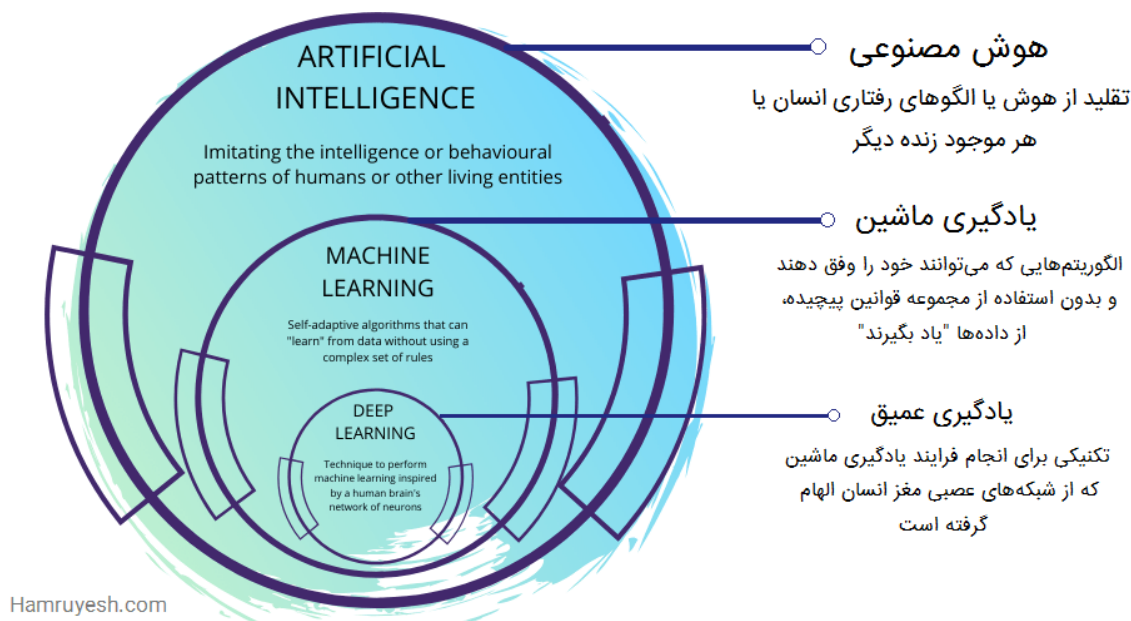
⁵⁰ Lead Movement

۲.۲. یادگیری عمیق

۲.۲.۱. بررسی اجمالی

هوش مصنوعی^{۵۱} (AI) (شکل ۲.۷) رشته‌ای از علوم کامپیوتری در حال توسعه برای یادگیری از تجربه و درک مفاهیم از طریق ارتباط آن با مفاهیم ساده‌تر است. سلسله مراتب مفاهیم، یادگیری کامپیوترها را با تجزیه مفاهیم پیچیده به مفاهیم ساده‌تر ممکن می‌سازد. برخی از الگوریتم‌های هوش مصنوعی بر دانش رمزگذاری شده با استفاده از قوانین استنتاج منطقی تکیه کرده است. این مفهوم به عنوان رویکرد پایگاه دانش شناخته می‌شود [۵۱].

یادگیری ماشین^{۵۲} زیرمجموعه‌ای از تکنیک‌های هوش مصنوعی است که قابلیت استخراج الگوها از داده‌های خام و یادگیری از آنها را از طریق روش‌های آماری را داراست. نمایش داده‌ها به شدت بر عملکرد یک الگوریتم یادگیری ماشینی ساده تأثیر می‌گذارد. یک الگوریتم یادگیری ماشینی ساده مستلزم انتخاب مجموعه‌ای از ویژگی‌های مناسب برای وظایف هوش مصنوعی است. در بسیاری از کارها دشوار است که بدانید کدام ویژگی‌ها باید استخراج شوند. یک راه حل برای این، رویکرد یادگیری ویژگی^{۵۳} است که به عنوان یادگیری عمیق^{۵۴} نیز شناخته می‌شود. مفهوم یادگیری ویژگی مبتنی بر به دست آوردن بهترین الگوریتم عملکردی با یادگیری از ویژگی‌ها به جای انتخاب ویژگی‌ها به صورت دستی است [۵۱].



شکل ۲.۷. نمودار ون اجزای هوش مصنوعی [۵۱].

⁵¹ Artificial Intelligence

⁵² Machine Learning

⁵³ Representation Learning


⁵⁴ Deep Learning

از سال ۲۰۰۶، یادگیری عمیق به عنوان حوزه تحقیق جدید و بسیار جالب یادگیری ماشین ظاهر شده است. یادگیری عمیق از پردازش اطلاعات غیرخطی چند لایه برای استخراج، تبدیل، تجزیه و تحلیل الگو و طبقه‌بندی ویژگی‌های تحت نظر یا بدون نظارت استفاده می‌کند. یادگیری عمیق زیرمجموعه‌ای از یادگیری ماشینی است که بر اساس الگوریتم‌هایی برای یادگیری نمایش‌های چند سطحی به منظور مدل‌سازی روابط پیچیده بین داده‌ها است. یادگیری درست ویژگی دیدگاهی در مورد یادگیری عمیق برای داده‌ها فراهم می‌کند. دیدگاه دیگر این است که عمق شبکه عصبی، یادگیری عمیق را قادر می‌سازد تا سطوح چندگانه پیچیده ویژگی و انتزاع را بیاموزد. عمق بیشتر شبکه عصبی را قادر می‌سازد تا دستورات بیشتری را به ترتیب اجرا کند [۵۲].

۲.۲.۲. شبکه‌های عصبی مصنوعی

روش‌های یادگیری عمیق مبتنی بر شبکه‌های عصبی مصنوعی^{۵۵} (ANN) هستند که هدف از آن‌ها از ابتدا ایجاد قابلیت تشخیص مشابه مغز انسان بوده است. ANN ها الهام گرفته شده از مغز انسان هستند، اما محاسبات آن‌ها بر اساس روش‌های کاملاً متفاوتی است. مغز یک سیستم غیرخطی است، در واقع یک کامپیوتر بسیار پیچیده می‌باشد که محاسبات خاصی را به صورت موازی از طریق نورون‌ها برای تشخیص الگو، ادراک و کنترل حرکت انجام می‌دهد. شبکه عصبی مصنوعی می‌تواند خطی یا غیرخطی باشد، در حال حاضر به پیچیدگی مغز انسان نمی‌رسد و محدودیت‌های بیشتری در محاسبات موازی دارد. شبکه‌های عصبی مصنوعی توانایی یادگیری با مثال را از طریق چندین تکرار دارند. آن‌ها این مزیت را دارند که نیازی به دانش عمیق در زمینه‌ای که در آن کاربرد دارند، وجود نداشته باشد. این منجر به تکامل سریع شبکه‌های عصبی مصنوعی در زمینه‌های مختلف علمی شده است [۵۳].

در یک تصویر بزرگ، یک شبکه عصبی معمولی از یک لایه ورودی، چندین لایه پنهان و یک لایه خروجی تشکیل شده است (شکل ۲.۸). بخش ورودی انواع مختلفی از داده‌های ورودی مانند سیگنال‌های زیستی، تصاویر، فیلم‌ها، گفتار، صداها، متن یا داده‌های عددی را می‌پذیرد. لایه‌های مخفی بیشتر از لایه‌های کانولوشن و تلفیقی تشکیل شده‌اند. لایه‌های کانولوشن الگوها و ویژگی‌های محلی را در داده‌های لایه‌های قبلی تشخیص می‌دهند. لایه‌های تلفیقی از نظر معنایی ویژگی‌های مشابه را باهم ادغام می‌کنند. لایه خروجی نتایج طبقه‌بندی یا پیش‌بینی را ارائه می‌دهد که اغلب توسط توابع فعال‌سازی مانند SoftMax کنترل می‌شوند [۵۴].



شکل ۲.۸. یک بلوک دیاگرام معمولی از یک مدل یادگیری عمیق.


⁵⁵ Artificial Neural Networks

در جزئیات بیشتر، شبکه‌های عصبی مصنوعی از واحدهای پردازش اطلاعات، نورون‌ها و ارتباطات مستقیم و وزنی بین آن نورون‌ها تشکیل شده‌اند. هر نورون ظرفیت محاسباتی محدودی دارد؛ که توسط تابع فعال‌سازی استفاده شده برای ترکیب سیگنال‌های ورودی به منظور محاسبه خروجی محدود شده است. سیگنال خروجی ممکن است در طول اتصالات وزنی به واحدهای دیگر ارسال شود. وزنه‌ها سیگنال ارسالی را تحریک یا مهار می‌کنند. سه عنصر اساسی در مدل عصبی وجود دارد:

۱. مجموعه‌ای از سیناپس‌ها یا حلقه‌های اتصال که با وزن مشخص می‌شوند.

۲. یک جمع‌کننده سیگنال‌های ورودی را با وزن سیناپسی مربوطه نورون جمع می‌کند.

۳. یک تابع فعال‌سازی برای محدود کردن دامنه خروجی یک نورون با محاسبه مجموع وزنی ورودی‌ها و بایاس‌ها، که برای تصمیم‌گیری در مورد شلیک یا عدم شلیک نورون استفاده می‌شود [۵۵].



شکل ۲.۹. مدل غیر خطی یک نورون [۵۵].

فعالیت خروجی نورون طبق رابطه (۱) بیان می‌شود:

$$y_k = \varphi\left(\sum_{j=1}^m w_{kj} x_j + b_k\right) \quad (1)$$

که در آن x_1, x_2, \dots, x_n سیگنال‌های ورودی و w_1, w_2, \dots, w_n وزن سیناپسی مربوطه نورون هستند، b_k بایاس اعمال شده خارجی، $\varphi(\cdot)$ تابع فعال‌سازی و y_k سیگنال خروجی نورون است. توابع فعال‌سازی می‌توانند خطی یا غیر خطی باشند که خروجی یک نورون را کنترل می‌کنند. چندین توابع فعال‌سازی مختلف وجود دارد که هر یک برای وظایف خاص یادگیری ماشین به کار می‌روند. انتخاب مناسب تابع فعال‌سازی نتایج شبکه عصبی را بهبود می‌بخشد [۵۶].


همانطور که قبلاً ذکر شد یک شبکه عصبی عمیق از لایه ورودی، لایه‌های پنهان و لایه خروجی تشکیل شده است. تمام لایه‌ها توسط گره‌ها تشکیل شده‌اند؛ که ساختار و عملکرد آن‌ها با جزئیات بیشتر در بالا ارائه شده است. یک شبکه عصبی

عمیق دارای تعدادی مولفه و فراپارامتر^{۵۶} است، که تنظیمات یک شبکه عصبی را مشخص می‌کند. اجزا و فراپارامترها عبارت‌اند از: توپولوژی شبکه، تابع تلفات، مقدار اولیه وزن، اندازه دسته^{۵۷}، نرخ یادگیری، دوره‌ها و آماده‌سازی داده‌ها. این مولفه‌ها و فراپارامترها با جزئیات بیشتر در بخش "تنظیم شبکه‌های عصبی عمیق" بررسی می‌شوند.

۲.۲.۳. دسته بندی تعدادی از شبکه های عصبی عمیق

یادگیری عمیق به انواع مختلفی از تکنیک‌ها و معماری‌های یادگیری ماشین اشاره دارد؛ که از پردازش اطلاعات غیرخطی چند لایه سلسله مراتبی استفاده می‌کنند. شبکه‌های عصبی عمیق را می‌توان به طور کلی به سه دسته عمده طبقه‌بندی کرد: ۱- شبکه‌های عمیق برای یادگیری بدون نظارت یا مولد، ۲- شبکه‌های عمیق برای یادگیری نظارت شده و ۳- شبکه‌های عمیق ترکیبی. این رویکردها چگونگی آموزش وزن یک شبکه عصبی تفاوت دارند [۵۷].

یادگیری بدون نظارت یا مولد به عدم استفاده از اطلاعات نظارتی خاص در فرآیند یادگیری اشاره دارد. در یادگیری بدون نظارت، تمام نمونه‌های آموزشی برچسب‌گذاری نمی‌شوند و هدف این است که نمونه‌ها بر اساس ویژگی‌هایشان به صورت خوشه‌ای تقسیم شوند. شبکه‌های یادگیری بدون نظارت، برای تشخیص همبستگی مرتبه بالا از داده‌های بدست آمده، برای تجزیه و تحلیل الگوی زمانی (که اطلاعات مربوط به برچسب‌های کلاس هدف در دسترس است) در نظر گرفته شده‌اند. شبکه‌های عمیق در دسته یادگیری بدون نظارت یا مولد می‌توانند مولد یا غیر مولد باشند، اما بیشتر آن‌ها ماهیت مولد دارند، مانند ماشین‌های بولتزمن محدود^{۵۸} (RBMs)، شبکه باور عمیق^{۵۹} (DBNs)، ماشین‌های بولتزمن عمیق^{۶۰} (DBM) و حذف نویز کلی^{۶۱} و رمزگذارهای خودکار^{۶۲} (شکل ۲.۱۰). شبکه عصبی بازگشتی^{۶۳} (RNN) را می‌توان به عنوان شبکه‌های عمیق برای یادگیری بدون نظارت در نظر گرفت. لازم به ذکر است این مدل برای یادگیری نظارت شده نیز استفاده می‌شود [۵۸].



شکل ۲.۱۰. تعدادی از شبکه های عصبی عمیق [۱۸].

⁵⁶ Hyperparameters

⁵⁷ Batch Size

⁵⁸ Restricted Boltzmann Machines

⁵⁹ Deep Belief Network

⁶⁰ Deep Boltzmann Machines

⁶¹ Generalized De-Noising

⁶² Auto-Encoders

⁶³ Recurrent Neural Network

رایج ترین رویکرد آموزشی، یادگیری نظارت شده است که در آن همه نمونه‌های آموزشی با کلاس صحیح برچسب‌گذاری می‌شوند. شبکه‌های یادگیری تحت نظارت به گونه‌ای طراحی شده‌اند که مستقیماً قدرت تمایز را برای اهداف طبقه‌بندی الگو فراهم کنند. در یادگیری نظارت شده، داده‌های برچسب زده شده هدف همیشه به صورت مستقیم یا غیرمستقیم در دسترس هستند. بیشتر معماری‌های تحت نظارت کم عمق هستند، مانند مدل پنهان مارکوف^{۶۴} (HMMs) و میدان‌های تصادفی شرطی^{۶۵} (CRF) [۵۹].

یادگیری نیمه نظارت شده دارای ویژگی‌های یادگیری تحت نظارت و بدون نظارت است؛ که در آن تنها زیر مجموعه کوچکی از داده‌ها برچسب‌گذاری شده است. شبکه‌های عصبی که از یادگیری نیمه نظارتی استفاده می‌کنند، شبکه‌های ترکیبی نامیده می‌شوند. شبکه‌های ترکیبی برای تمایز داده‌ها با نتایج شبکه‌های عمیق مولد یا بدون نظارت در نظر گرفته شده‌اند. تفاوت و تمیز در شبکه‌های عمیق ترکیبی می‌تواند با بهینه‌سازی یا با تنظیم شبکه‌های یادگیری نظارت‌شده یا با استفاده از معیارهای متمایز کننده برای یادگیری نظارت‌شده برای تخمین پارامترها در هر یک از شبکه‌های عمیق مولد یا بدون نظارت انجام شود.

یادگیری تقویتی به معنای رویکرد آموزشی است که در آن عامل (یک تصمیم گیرنده) تلاش می‌کند تا بهره‌وری‌های مورد انتظار را در یک محیط خاص در طولانی مدت به حداکثر برساند. عامل از طریق آزمون‌ها و خطاها برای محاسبه یک استراتژی رفتاری با یک محیط معین تعامل دارد. یکی دیگر از رویکردهای رایج، تنظیم دقیق است؛ که در آن وزن‌هایی قبلاً آموزش داده شده‌اند، به عنوان نقطه شروع برای مجموعه داده‌های تنظیم‌شده جدید یا یک محدودیت جدید استفاده می‌شوند. تکنیکی که در آن وزن‌های آموزش دیده قبلی با یک مجموعه داده جدید تنظیم می‌شوند، یادگیری انتقالی نامیده می‌شود [۶۰].

۲.۲.۴. معماری‌ها

۲.۲.۴.۱. شبکه‌های فیدبک عمیق


شبکه‌های فیدبک عمیق (شکل ۲.۱۱) که به عنوان شبکه‌های عصبی فیدبک‌دار یا پرسپترون‌های چندلایه (MLP) نیز نامیده می‌شوند، اولین و ساده‌ترین مدل‌های یادگیری عمیق هستند. یک شبکه عصبی فیدبک‌دار فقط دارای اتصالات مستقیم از هر نورون در یک لایه به نورون‌های لایه بعدی به سوی لایه خروجی است. محاسبات شبکه فیدبک بر اساس تقریب برخی از تابع‌های f^* است. این مدل‌ها فیدبک نامیده می‌شوند؛ زیرا داده‌ها از طریق تابع x بدون اینکه خروجی‌ها به خودشان برگردند، بررسی می‌شوند. شبکه‌های عصبی فیدبک معمولاً بسیاری از توابع مختلف را در یک زنجیره ترکیب می‌کنند. نماد ساختار زنجیره‌ای شبکه عصبی فیدبک سه لایه ساختار یافته برای توابع $f^{(1)}$ ، $f^{(2)}$ و $f^{(3)}$ ؛ $f(x) = f^{(3)}$

⁶⁴ Hidden Markov Model

⁶⁵ Conditional Random Fields

دهنده عمق مدل است [۶۱]. $f^{(2)}(f^{(1)}(x))$ می‌باشد؛ که در آن $f^{(1)}$ لایه اول، $f^{(2)}$ لایه دوم و $f^{(3)}$ لایه سوم شبکه است. طول کلی زنجیره نشان

پس انتشار^{۶۶} رایج‌ترین تکنیک یادگیری است که در شبکه‌های عصبی فیدبک‌دار استفاده می‌شود. پس انتشار یک روش نزولی گرادیان برای آموزش وزن شبکه عصبی با تابع خطا است. این روش، گرادیان تابع خطا را با توجه به وزن شبکه عصبی محاسبه می‌کند. یک مشکل اصلی در پس انتشار این است که الگوریتم تنها یک حداقل محلی تابع خطا را به جای حداقل کلی پیدا می‌کند. علاوه بر این، در برخی موارد یک شبکه ممکن است با داده‌های آموزشی بیش‌برازش^{۶۷} شود، زمانی که تنها مقدار محدودی از داده در دسترس باشد که منجر به عملکرد ضعیف با داده‌های آزمایشی می‌شود [۶۲].



شکل ۲.۱۱. مثالی از یک شبکه پیشخور با یک لایه ورودی، دو لایه پنهان و یک لایه خروجی.

شبکه‌های عصبی عمیق به طور قابل توجهی نتایج شبکه‌های عصبی مصنوعی را بهبود بخشیده‌اند، اما آن‌ها با یک مشکل جدی با نام بیش‌برازش مواجه شده‌اند. همچنین، آموزش و استفاده از شبکه‌های عصبی عمیق کند است. نظم‌دهی^{۶۸} به این معناست که می‌توان از اضافه کردن وزن‌های شبکه به یک تابع تلفات، برای رفع مشکل بیش‌برازش استفاده کرد. دو تکنیک نظم‌دهی متفاوت وجود دارد که $L1$ و $L2$ نامیده می‌شوند. در تنظیم $L1$ ، وزن‌های مطلق به تابع تلفات اضافه می‌شوند تا مدل تعمیم‌یافته‌تر شود. در تنظیم $L2$ ، مجذور وزن‌ها به تابع تلفات اضافه می‌شود [۶۳].

در کنار $L1$ و $L2$ ، تکنیک نظم‌دهی حذف تصادفی^{۶۹} نیز وجود دارد. ایده اصلی حذف تصادفی این است که لایه حذف به طور تصادفی واحدهای شبکه عصبی را در طول آموزش با جلوگیری از تطبیق بیش از حد واحدها حذف می‌کند (شکل ۲.۱۲). حذف تصادفی به معنای حذف موقت واحدهای شبکه به همراه تمام اتصالات ورودی و خروجی آن است. آقای هینتون و همکاران [۶۳] نشان داده است که حذف تصادفی باعث بهبود عملکرد شبکه‌های عصبی می‌شود. لایه‌های حذفی را می‌توان فقط برای مناطقی که به طور کامل به شبکه عصبی متصل هستند، اعمال کرد؛ حتی اگر آن‌ها محدود به


^{۶۶} Backpropagation

^{۶۷} Overfit

^{۶۸} Regularization

^{۶۹} Dropout Regularization

شبکه‌های عصبی فیدبک‌دار نیستند. افزایش داده‌ها نیز یکی از تکنیک‌های کاهش بیش برآزش است. افزایش داده فرآیندی است که در آن داده‌ها به طور مصنوعی با استفاده از تبدیلات حفظ برجسب بسط داده می‌شوند.



شکل ۲.۱۲. شبکه عصبی استاندارد و شبکه عصبی با انصراف.


مشکل شبکه عصبی فیدبک‌دار که دارای اتصالات استاندارد می‌باشد؛ این است که مدل ویژگی‌های سطح بالا را یاد می‌گیرد و این منجر به مشکل ناپدید شدن گرادیان می‌شود. برای غلبه بر مشکل ناپدید شدن گرادیان، شبکه‌های فیدبک‌دار با اتصالات میانبر^{۷۰} توسعه داده شده است. یک شبکه عصبی می‌تواند اتصالات میانبری داشته باشد که از یک یا چند لایه عبور می‌کند (شکل ۲.۱۳). در شبکه‌های فیدبک‌دار این اتصالات میانبر را می‌توان تنها به سوی لایه خروجی هدایت کرد. کلمه پرسپترون بیشتر اوقات برای توصیف یک شبکه فیدبک‌دار با اتصال میانبر استفاده می‌شود.

برخی از مطالعات نشان می‌دهند که اتصالات میانبر نتایج بهتری نسبت به مدل‌هایی که اتصال استاندارد دارند به دست می‌دهند. آقای ژانگ و همکاران [۸۵] ثابت کرده‌اند که شبکه‌های باقی‌مانده برای بهینه‌سازی آسان‌تر هستند و می‌توانند از افزایش قابل توجه عمق شبکه‌ها، دقت را به دست بیاورند. این مطالعه مدعی شده است که با پرش از روی لایه‌ها، شبکه از مشکل ناپدید شدن گرادیان جلوگیری می‌کند. شبکه باقی‌مانده از جمع عناصر (جمع درایه‌ای) استفاده می‌کند. اتصال پیچشی متراکم^{۷۱} شبکه را قادر می‌سازد تا اطلاعات اضافی را از تمام لایه‌های قبلی دریافت کند و الگوهای ویژگی خود را به تمام لایه‌های بعدی ارسال کند (شکل ۲.۱۳). از آنجایی که لایه‌ها اطلاعات همه لایه‌های قبلی را دریافت می‌کنند،

⁷⁰ Shortcut Connection

⁷¹ Dense-Net

شبکه به پارامترهای کمتر و محاسبات کمتری برای دستیابی به نتایج بهتر نسبت به مدل‌های دارای اتصالات استاندارد و میانبر نیاز دارد.



شکل ۲.۱۳. الف) اتصال استاندارد، ب) شبکه اتصال میانبر با پرش دو لایه، و ج) اتصال شبکه متراکم [۸۵].

۲.۲.۴.۲. شبکه‌های عصبی کانولوشنال

شبکه‌های عصبی کانولوشنال^{۷۲} (CNN) شبکه‌های عصبی مصنوعی هستند که برای پردازش توپولوژی شبکه مانند تخصص دارند. آن‌ها انواعی از پرسپترون‌های چند لایه^{۷۳} (MLPs) که الهام گرفته شده از بیولوژیکی هستند، می‌باشند. آقای لکان و همکاران [۵۵] شبکه‌های کانولوشنال را در اوایل دهه ۱۹۰۰ معرفی کردند. یک مدل شبکه عصبی کانولوشنال معمولی از چندین کانولوشن، ادغام یا تلفیق و لایه‌های کاملاً متصل تشکیل شده است. هر لایه CNN مفهوم سطح بالاتری از داده‌های ورودی را ایجاد می‌کند که به عنوان نقشه ویژگی نامیده می‌شود. محاسبات داخل CNN ها بر اساس نوع خاصی از عملیات خطی به نام کانولوشن است. آقای بنگیون و همکاران CNN ها را چنین توصیف می‌کنند: «شبکه‌های کانولوشنال به سادگی شبکه‌های عصبی هستند که از کانولوشن به جای ضرب ماتریس عمومی حداقل در یکی از لایه‌های خود استفاده می‌کنند.

CNN ها عملکرد عالی در تشخیص و طبقه‌بندی الگو از خود نشان داده اند. CNN ها ایده سیستم‌های یادگیری ماشین سنتی را با ارائه تعاملات پراکنده، به اشتراک‌گذاری پارامترها و نمایش معادل بهبود می‌بخشند. CNN یکی از شبکه‌های عصبی است که برای طبقه‌بندی سری‌های زمانی در کنار شبکه عصبی بازگشتی^{۷۴} (RNN) مناسب است. CNN قادر به یادگیری ویژگی‌های عمیق در الگوهای بازگشتی است و بنابراین؛ برای استنباط از فعالیت‌های تکراری طولانی مدت خوب است. CNN ها درجاتی از تغییر و واریانس اعوجاج را به دلیل میدان‌های دریافتی محلی، وزن‌های مشترک و در برخی موارد، نمونه‌گیری فرعی مکانی و زمانی تضمین می‌کنند. وابستگی محلی، عدم تغییر مقیاس و پشتیبانی ورودی چند

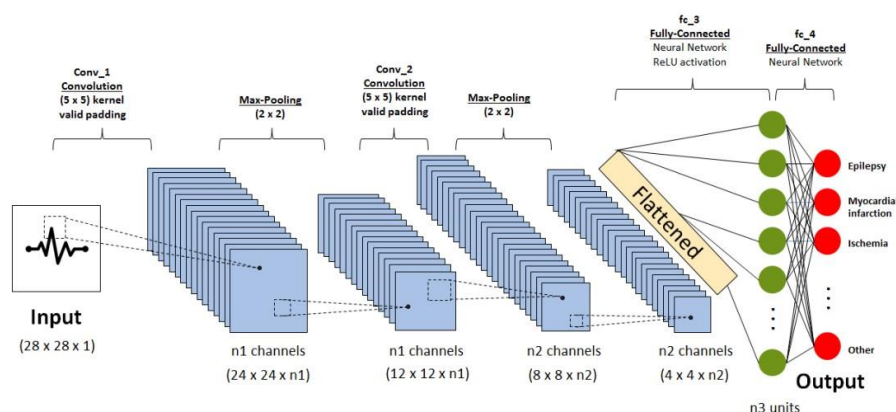
^{۷۲} Convolutional neural networks

^{۷۳} Multi-Layer Perceptron

^{۷۴} recurrent neural network

متغیره از مزایای CNN در مقایسه با مدل‌های دیگر هستند. با این حال، در برخی موارد، وابستگی محلی ممکن است نامطلوب باشد؛ زیرا اندازه کرنل‌های کانولوشنال حوزه‌ی وابستگی‌های گرفته شده بین نمونه‌ها را محدود می‌کند [۶۴].

داده‌هایی که می‌توانند به CNN ها اعمال شوند، به عنوان مثال شبکه یک بعدی داده‌های سری زمانی، تصاویر به عنوان یک شبکه دو بعدی از پیکسل‌ها یا حتی شبکه‌های چند بعدی پیچیده تر مانند سه بعدی هستند. همه CNN ها بدون توجه به ابعاد داده‌های ورودی داده شده از یک رویکرد پیروی می‌کنند. تنها تفاوت کلیدی این است که چگونه آشکارساز ویژگی که به عنوان فیلتر نیز نامیده می‌شود، روی داده‌ها حرکت می‌کند. در CNN های یک بعدی (1D)، محاسبات کانولوشن به صورت یک بعدی، در حالی که در دو بعدی (2D) به صورت دو بعدی و در سه بعدی (3D) به صورت سه بعدی انجام می‌شود. در CNN_2D (شبکه‌های عصبی کانولوشنی دو بعدی) پیچیدگی محاسباتی به طور قابل توجهی کمتر از CNN های 2D یا 3D است. مطالعات اخیر نشان داده است که CNN_1D ها قادر به یادگیری وظایف چالش برانگیز مربوط به سیگنال‌های 1D هستند. اغلب CNN_2D به شبکه‌های بسیار عمیق‌تری نسبت به CNN_1D که شامل سیگنال‌های یک بعدی هستند، نیاز دارند. CNN_1D ها به دلیل نیازهای محاسباتی کم برای کاربردهای کم هزینه و با سرعت بالا مناسب هستند [۶۵].



شکل ۲.۱۴. نمونه‌ای از CNN با دو لایه کانولوشن (Conv1d و Conv2d)، دو لایه max-pooling و دو لایه کاملاً متصل (fc_3 و fc_4) [۶۵].

CNN از لایه‌های کانولوشنال و کاملاً متصل همانطور که در شکل ۲.۱۴ نشان داده شده است، تشکیل شده است، اما لایه‌های اختیاری مانند لایه‌های فعال‌سازی غیرخطی، ادغام یا تلفیق و عادی‌سازی نیز وجود دارد. یک تابع فعال‌سازی غیرخطی اغلب بعد از هر لایه کانولوشنی یا کاملاً متصل اعمال می‌شود. متداول‌ترین تابع فعال‌سازی، واحد خطی اصلاح‌شده^{۷۵} (ReLU) است؛ که به دلیل توانایی آن در فعال کردن آموزش سریع است. لایه‌های تلفیق ابعاد نقشه‌های ویژگی را کاهش می‌دهند. کاهش ابعاد نقشه‌های ویژگی، شبکه را قادر می‌سازد تا نسبت به جابجایی‌ها و اعوجاج‌های

⁷⁵ Rectified Linear Unit

کوچک، قوی و ثابت باشد. لایه تلفیق را می‌توان بر اساس اندازه میدان دریافتی آن پیکربندی کرد. گام‌های ادغام لایه‌ها نحوه چرخش فیلتر به دور مقدار ورودی را تعیین می‌کند. انواع مختلفی از لایه‌های تلفیق مانند حداکثر تلفیق، تلفیق متوسط و تجمیع میانگین کلی وجود دارد [۵۵].

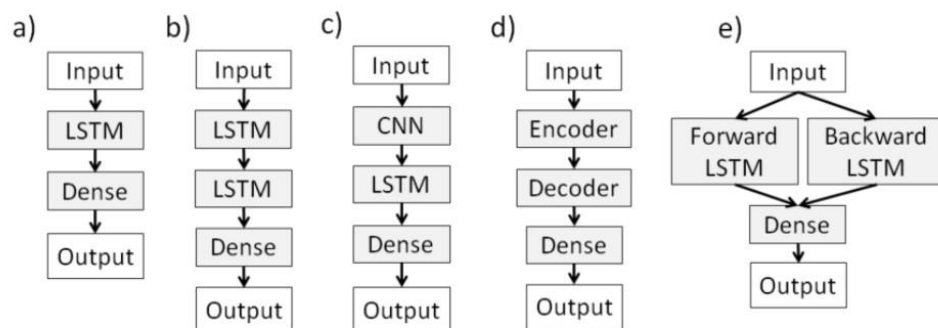
۲.۲.۴.۳. شبکه‌های حافظه کوتاه مدت مکرر و بلند مدت

شبکه‌های عصبی مکرر با شبکه‌های عصبی فیدبک‌دار تفاوت دارند؛ به نحوی که حداقل یک حلقه فیدبک دارند. در یک حلقه فیدبک، هر نورون خروجی‌های خود را به ورودی‌های همه نورون‌های دیگر لایه قبلی برمی‌گرداند. شبکه‌های عصبی مکرر زمانی مفید هستند که راه‌حل نه تنها به ورودی‌های فعلی، بلکه به همه ورودی‌های قبلی بستگی داشته باشد. در طول آموزش، شبکه عصبی مکرر، داده‌ها را از طریق یک شبکه شامل حلقه فیدبک از خروجی‌ها به ورودی‌ها اعمال می‌کند تا زمانی که مقادیر خروجی‌ها تغییر نکنند. می‌توان گفت که شبکه‌های عصبی بازگشتی دارای حافظه هستند؛ زیرا راه حل بر اساس ورودی فعلی و خروجی‌های قبلی است [۶۶].

شبکه‌های عصبی مکرر مانند شبکه حافظه کوتاه مدت - بلند مدت ۷۶ (LSTM) پشتیبانی بومی را برای داده‌های ورودی متشکل از دنباله‌ای از مشاهدات اضافه می‌کنند. LSTM قادر است بسیاری از وظایف سری زمانی را با استفاده از پنجره‌های زمانی با اندازه ثابت بهتر از فیدبک حل کند. LSTM قادر است همبستگی‌های بلندمدت را به ترتیب بیاموزد و بنابراین؛ می‌تواند به طور دقیق توالی‌های چند متغیره پیچیده را مدل کند. RNN و LSTM از رابطه مرتبه زمانی بین قرائت‌ها (عمل خواندن) استفاده می‌کنند و بنابراین؛ قادر به تشخیص فعالیت‌های کوتاهی هستند که دارای نظم طبیعی می‌باشند [۶۷].

چندین معماری مختلف LSTM وجود دارد. LSTM‌های وانیلی ساده‌ترین مدل‌های LSTM با سلول حافظه از یک لایه LSTM در ساختار شبکه ساده هستند. شبکه‌های LSTM انباشته حاوی چندین لایه LSTM مخفی هستند که روی هم در شبکه‌های عمیق قرار گرفته‌اند. انباشته‌سازی، شبکه را قادر می‌سازد تا به ساختار عمیق‌تری نسبت به LSTM وانیلی دست یابد. CNN-LSTM مدلی است که از مدل CNN و مدل LSTM که روی هم قرار گرفته‌اند، تشکیل شده است. مدل CNN-LSTM قدرت‌های مدل‌های CNN و LSTM را با هم ترکیب می‌کند. در مدل CNN-LSTM، CNN برای یادگیری ویژگی‌های نمونه‌ها استفاده می‌شود، در حالی که LSTM می‌تواند برای پشتیبانی از نوع ورودی و خروجی دنباله‌ای استفاده شود. رمزگذار-رمزگشا LSTM به معنای یک مدل LSTM است که شامل LSTM رمزگذار و شبکه‌های رمزگشا LSTM به طور جداگانه است. رمزگذار LSTM یک دنباله با طول متغیر را به یک بردار با طول ثابت نگاشت می‌کند، در حالی که شبکه رمزگذار LSTM بردار را به دنباله‌ای با طول متغیر نگاشت می‌کند. در LSTM دو طرفه، دنباله ورودی هم به جلو و هم به عقب آموخته می‌شود، در حالی که در LSTM مولد، رابطه ساختاری دنباله ورودی به

گونه‌ای آموخته می‌شود که بتواند دنباله‌های جدیدی تولید کند. معماری‌ها به صورت بلوک دیاگرام در شکل ۲.۱۵ ارائه شده است [۶۸].



شکل ۲.۱۵. بلوک دیاگرام های معماری LSTM: (a) LSTM وانیلی، (b) LSTM انباشته، (c) CNN LSTM، (d) رمزگذار-رمزگشا LSTM و (e) LSTM دو طرفه [۶۸].

۲.۲.۵. تنظیم شبکه‌های عصبی عمیق

تنظیم شبکه‌های عصبی عمیق به معنای فرآیندی است که در آن ترکیبات مختلف پارامترها و اجزای یک شبکه برای بهبود عملکرد یک مدل، آزمایش می‌شوند. این پارامترها که ساختار کلی یک مدل را تعریف می‌کنند، فراپارامتر نامیده می‌شوند. به عنوان مثال، فراپارامترها تعداد نوروها در یک لایه، تعداد لایه‌های پنهان، تابع فعال‌سازی، بهینه‌سازی، نرخ یادگیری معماری، تعداد دوره‌ها، اندازه دسته‌ای و غیره هستند. برخی از آن‌ها مهم‌تر از سایر اجزا هستند. انتخاب فراپارامترها و مؤلفه‌ها برای الگوریتم یادگیری حیاتی هستند. با این حال، هیچ دستور العملی برای یافتن فراپارامترهای بهینه برای یک مدل وجود ندارد؛ زیرا آن‌ها تا حد زیادی به داده وابسته هستند و مشکل‌ساز می‌باشند.

مفهوم توپولوژی شبکه شامل دو جزء است: ۱- تعداد گره‌ها در هر لایه پنهان و ۲- تعداد لایه‌های پنهان. توپولوژی شبکه به ظرفیت شبکه برای تناسب آن با طیف گسترده‌ای از توابع اشاره دارد. ظرفیت شبکه کنترل می‌کند که آیا یک مدل بیش برآزش می‌کند یا نه؟. بنابراین، مدل با لایه‌های بیشتر و گره‌های بیشتر در هر لایه، ظرفیت بالاتری نسبت به مدلی دارد که تعداد آن‌ها کمتر است [۶۹].

شبکه‌های عصبی با استفاده از کاهش گرادیان تصادفی آموزش داده می‌شوند؛ که نیاز به انتخاب تابع تلفات دارد. تابع تلفات معیاری است که خطای مدل را محاسبه می‌کند. خطای مدل، عملکرد یک مدل با وزن‌های خاص را توصیف می‌کند. تابع تلفات تابع هدفی است که در حال مینیمایز کردن (به حداقل رساندن) است و به آن تابع هزینه یا تابع خطا نیز می‌گویند. انتخاب تابع تلفات به انتخاب تابع فعال‌سازی خروجی بستگی دارد. انتخاب اشتباه تابع تلفات ممکن است منجر به گمراهی در ارزیابی عملکرد مدل شود [۷۰].

مقدار اولیه وزن به معنای روشی است که در آن وزن‌های یک مدل با مقادیر تصادفی کوچک قبل از فرآیند آموزش مقداردهی می‌شوند. چندین روش مختلف برای مقداردهی اولیه وزن‌ها برای یک شبکه عصبی مانند روش Xavier وجود دارد، با این حال هنوز بهترین روش برای مقداردهی اولیه وزن‌ها مورد بررسی قرار نگرفته است. پیش‌آموزش لایه‌ای حریصانه^{۷۷} و یادگیری انتقالی می‌تواند به عنوان طرح‌های اولیه استفاده شود. پیش‌آموزش لایه‌ای حریصانه تکنیکی برای توسعه شبکه‌های عصبی عمیق‌تر با مقداردهی اولیه وزن‌ها می‌باشد، مقدار دهی در یک بازه نزدیک به حداقل محلی مناسب است. یادگیری انتقالی به فرآیندی اطلاق می‌شود که در آن مدلی که در مورد یک مسئله آموزش دیده است برای مشکل دیگر در جهت بهبود تعمیم استفاده می‌شود.

اندازه دسته‌ای که به عنوان اندازه کوچک نیز نامیده می‌شود؛ تعداد نمونه‌هایی است که برای تخمین خطا قبل از به روز رسانی پارامترهای مدل استفاده می‌شود. اندازه دسته‌ای بر سرعت و ثبات فرآیند آموزش تأثیرگذار است. اندازه دسته کوچک نشان داده است که تعمیم را بهبود می‌بخشد و در یک زمان در طول فرآیند آموزش به حافظه کمتری نیاز دارد. یک مقدار پیش فرض خوب برای اندازه دسته ۳۲ است؛ اما بسته به تنظیمات و داده‌ها می‌توان آن را بین یک تا چند صد دسته انتخاب کرد [۷۱].

دوره^{۷۸} به معنای تعداد عبور از مجموعه داده آموزشی است، که یک مدل کامل می‌کند. توقف آموزش در زمان مناسب برای بهبود تعمیم بسیار مهم است. توقف زودهنگام روشی است که در آن آموزش در زمان رخ دادن کوچکترین خطا با توجه به مجموعه داده‌های اعتبارسنجی متوقف می‌شود. توقف زودهنگام به عنوان یکی از انواع روش‌های نظم دهی یاد می‌شود. معیارهایی که به طور متوسط دیرتر آموزش یا همان یادگیری را متوقف می‌کنند، در مقایسه با توقف سریعتر منجر به تعمیم بهتر می‌شوند. با این حال، نتایج استفاده از معیارهای توقف بعدی بسیار متفاوت است. معیارهایی که باید برای توقف اولیه در نظر گرفته شوند عبارتند از: عدم تغییر، کاهش، تغییر میانگین یا تغییر مطلق در استاندارد در طول تعداد معینی از دوره‌ها [۷۲].

نرخ یادگیری که اندازه گام نیز نامیده می‌شود، مقداری است که هر پارامتر مدل در هر تکرار به خود می‌گیرد. این کنترل می‌کند که یک مدل با چه سرعتی یک مشکل را یاد می‌گیرد. نرخ یادگیری به شدت با تعداد دوره‌ها و اندازه دسته مرتبط است. نرخ یادگیری تنهاترین و مهمترین فرآپارامتری است که باید برای مدلی تنظیم شود؛ که از کاهش گرادیان تصادفی استفاده می‌کند. مقادیر دامنه‌ای که باید برای نرخ یادگیری در نظر گرفته شوند کمتر از ۱ و بیشتر از ۰.۰۰۰۰۰۱ هستند [۷۳].

تکنیک‌های مختلفی برای تنظیم فرآپارامتر برای دستیابی به عملکرد بهتر مدل وجود دارد. جستجوی دستی، تکنیکی برای انتخاب دستی بهترین مقدار نماینده (کاندید) برای فرآپارامترهای یک مدل است. نقطه شروع خوب استفاده از مقادیر پیش فرض یک مدل و تغییر فرآپارامترهای یک مدل بر اساس عملکرد مدل است. جستجوی شبکه ای، تکنیکی است که

⁷⁷ Greedy Layer-Wise Pretraining

⁷⁸ Epoch

ترکیبات شبکه مانند مقادیر ارائه شده هر فرایارامتر را آزمایش و بررسی می‌کند. نقطه ضعف این تکنیک این است که شبکه همیشه ترکیب فرایارامتر خوبی ندارد. جستجوی تصادفی، تکنیکی است که در آن ترکیب‌های فرایارامتر به صورت تصادفی انتخاب می‌شوند. این تکنیک فضای فرایارامتر بزرگ‌تری را فراهم می‌کند و در نتیجه احتمال بسیار بیشتری برای انتخاب ترکیب‌های فرایارامتر بهتر برای بهبود عملکرد یک مدل را فراهم می‌کند. بهینه سازی بیزی^{۷۹}، تکنیکی است که انتخاب فرایارامترها را تسریع می‌بخشد. این رویکرد، ترکیب‌های فرایارامتر را بر اساس ارزیابی‌های قبلی انتخاب می‌کند و بر روی آن مناطقی از فضای فرایارامتر تمرکز می‌کند که احتمالاً بهترین مقادیر آزمایش را به ارمغان می‌آورد [۷۴].

۲.۲.۶. گردش کار یادگیری عمیق در پردازش سیگنال

شبکه‌های عصبی یادگیری عمیق به‌ویژه برای طبقه‌بندی تصویر استفاده می‌شوند، اما برای انجام پردازش سیگنال نیز مناسب هستند. شبکه‌های عصبی قادر به پردازش سیگنال یک بعدی، داده‌های سری زمانی یا حتی متن به عنوان داده ورودی هستند. مراحل اصلی در گردش کار یادگیری عمیق عبارت‌اند از: وارد کردن داده‌ها، پیش پردازش داده‌ها، پیکربندی معماری شبکه، آموزش شبکه و بررسی درستی شبکه و بررسی دقت شبکه؛ زیرا هدف یافتن بهترین معماری شبکه است، که بالاترین دقت را برای داده‌های آزمایشی ایجاد کند. داده‌های آزمایشی باید حاوی داده‌های مشابهی با داده‌های موجود در محیط استقرار باشند.



شکل ۲.۱۶. گردش کار یک شبکه یادگیری عمیق.

معمولاً یادگیری عمیق به پیش پردازش و استخراج ویژگی زیادی نیاز ندارد؛ بنابراین اغلب تصویر خام برای دریافت نتایج به شبکه ارسال می‌شود. یادگیری عمیق ایده‌آل با سیگنال‌ها کار نمی‌کند؛ زیرا اغلب داده‌های سیگنال خام متغیر و کوچک‌تر از داده‌های تصویر و دارای نویز هستند. بنابراین، داده‌های سیگنال خام نیاز به پیش پردازش دقیق و گاهی اوقات استخراج ویژگی برای اطمینان از بهترین نتایج ممکن دارند. وظایف احتمالی پیش پردازش برای مثال، حذف سیگنال‌ها با مقادیر ثابت، نرمالیزه کردن پیش‌بینی‌کننده‌های آموزشی یا حذف نویز است. فیلترهای کلاسیک پردازش سیگنال در پیش پردازش استفاده می‌شوند، اما چالش‌های این رویکردها این است که آنها برخی از اطلاعات سیگنال مورد نظر را همراه با نویز فیلتر می‌کنند. حذف نویز با شبکه‌های عصبی، انتخاب خوبی برای بهبود کیفیت سیگنال‌ها، به عنوان مثال برای افزایش نسبت نویز به سیگنال است [۷۵].

مقیاس‌بندی داده‌ها در مرحله پیش‌پردازش توصیه می‌شود؛ زیرا ورودی‌های مقیاس‌بندی نشده ممکن است باعث روند یادگیری کند و ناپایدار شوند. متغیرهای ورودی ممکن است واحدهای متفاوتی داشته باشند، به این معنی باشد که متغیرها

⁷⁹ Bayesian Optimization

مقیاس‌های متفاوتی دارند. مقادیر ورودی باید مقادیر کوچکی در محدوده ۰-۱ باشند یا با میانگین صفر و انحراف معیار یک استانداردسازی شوند. اگر توزیع داده‌ها شکل توزیع نرمال داشته باشد، باید استانداردسازی شود، در غیر این صورت داده‌ها باید نرمالیزه شوند. علاوه بر این، متغیرهای خروجی باید مقیاس‌بندی شوند تا با مقیاس تابع فعال سازی لایه خروجی یک شبکه عصبی مطابقت داشته باشند [۷۶].

پیش‌بینی سری‌های زمانی یکی از چالش برانگیزترین وظایف در داده‌های سری زمانی بسیار نامتعادل هستند. مثال عینی داده‌های صرع است که ثبت‌ها ممکن است چندین ساعت طول بکشد، اما تشنج صرع ممکن است تنها چند ثانیه تا چند دقیقه طول بکشد. در این حالات، الگوریتم‌های یادگیری، مدل‌ها را به سوی کلاس غالب بایاس می‌کنند، که منجر به کاهش عملکرد می‌شود. استراتژی‌های نمونه‌گیری مجدد مختلفی برای حل این نوع مسائل وجود دارد، مانند نمونه‌گیری تصادفی، بیش‌نمونه‌گیری تصادفی و نمونه‌گیری تصادفی با روش نمونه‌گیری بیش از حد اقلیت مصنوعی. در کنار تکنیک‌های نمونه‌گیری مجدد، راه دیگری برای مقابله با داده‌های نامتعادل، یادگیری حساس به هزینه است. استراتژی‌های نمونه‌گیری مجدد و یادگیری حساس به هزینه می‌توانند به طور قابل توجهی ارزیابی پیش‌بینی مدل‌ها را بهبود بخشند [۷۷].

به منظور آماده‌سازی داده‌های سیگنال برای شبکه‌های عصبی، داده‌های سیگنال اغلب به طیف‌نگارها^{۸۰}، موجک‌ها^{۸۱} یا تبدیل فوریه تبدیل می‌شوند. طیف نگار یک تبدیل زمان-فرکانس است که داده‌های سیگنال خام را به عنوان یک تصویر دوبعدی نشان می‌دهد. تبدیل موجک شبیه به عملکرد طیف‌نگارها است، اما شامل تفکیک زمانی برای اجزای سیگنال غیتناوبی است. همچنین، موجک‌ها برای استخراج ویژگی‌ای به نام شبکه‌های کانولوشنی پراکندگی موجک یا پراکندگی ثابت استفاده می‌شوند. تبدیل فوریه کوتاه مدت^{۸۲} (STFT) سیگنال را به یک سیگنال دو بعدی در حوزه فرکانس تبدیل می‌کند [۷۵].

۲.۳. کارهای مرتبط

بیش از سه دهه است که محققان تلاش کرده‌اند تا مشکل تشخیص تشنج صرعی مبتنی بر EEG را حل کنند تا به پزشکان در کارشان یاری رسانند. بنابراین، تعداد زیادی از مقالات تحقیقاتی برای شناسایی تشنج صرعی منتشر شده است. مقالات پژوهشی منتشر شده را می‌توان به سه مسئله اصلی طبقه بندی کرد. اولین و ساده‌ترین مورد در مقایسه با سایر مسائل، تشخیص کلاس‌های متمایز است: الگوهای EEG طبیعی و ایکتال. مسئله دوم، تمایز الگوهای EEG طبیعی، بین ایکتال و اینترایکتال است. سومین و چالش برانگیزترین مسئله پرداختن به تمایز بین طبقات است: الگوهای EEG نرمال،

⁸⁰ Spectrogram

⁸¹ Wavelets

⁸² Short-Time Fourier Transform

ایکتال، اینتر ایکتال، پسا ایکتال و پیش ایکتال. با توجه به موضوع پایان نامه تمرکز این بخش فقط بر روی پیشینه مربوط به مسئله طبقه بندی برای بیان تفاوت‌های الگوهای EEG طبیعی و ایکتال تمرکز دارد [۷۸].

روش‌ها و تکنیک‌های مختلفی وجود دارد که بیان می‌کند چگونه می‌توان یک آشکارساز تشنج صرعی ایجاد کرد. از دیدگاه یادگیری ماشین در سال ۲۰۰۵، آقای اعرابی و همکارانش [۸۶] سیستم تشخیص خودکار تشنج صرعی را با استفاده از مجموعه‌ای از ویژگی‌های EEG ارائه کرد. آن‌ها ویژگی‌هایی را از حوزه زمان، دامنه فرکانس، دامنه موجک استخراج کردند تا همراه با ضرایب رگرسیون خودکار^{۸۳} و ویژگی‌های مغزی در یک شبکه عصبی پسا انتشار^{۸۴} (BNN) اعمال شوند. این مجموعه تحقیقاتی به میانگین دقت طبقه‌بندی ۹۳.۰۰ درصد دست یافت. در سال ۲۰۰۷، آقای پولات و همکاران [۸۷] با استفاده از تبدیل فوریه سریع^{۸۵} (FFT) به عنوان ورودی برای طبقه‌بندی درخت تصمیم، به دقت بالاتر ۹۸.۶۸٪ دست یافتند. در همان سال، جناب سوباسی و همکاران [۷۹] با استفاده از تبدیل موجک برای استخراج باندهای فرکانسی EEG به عنوان ورودی برای شبکه‌های تجمیع خبرگان^{۸۶} (ME) به دقت قابل مقایسه ۹۴.۵۰٪ دست یافت.

در سال ۲۰۰۸، جناب میروفسکی و همکاران [۸۸] برای اولین بار شبکه‌های عصبی کانولوشنال را با SVM برای پیش‌بینی تشنج صرع مقایسه کردند. میروفسکی و همکاران بر روی ویژگی‌های انباشته‌ای که رابطه بین جفت کانال‌های EEG را رمزگذاری می‌کند، مانند همبستگی متقابل، وابستگی متقابل غیرخطی، تفاوت توان لیاپانوف و همزمانی مبتنی بر تحلیل موجک مانند قفل شدن فاز متمرکز شدند. آنها پیش‌بینی تشنج با هشدار کاذب صفر را در ۲۰ بیمار از ۲۱ بیمار به دست آوردند، در حالی که ۱۱ مورد فقط با استفاده از SVM بودند. یک سال بعد، آقای چاداکا و همکاران [۸۰] از ماشین برداری پشتیبان^{۸۷} (SVM) همراه با سه ویژگی آماری به عنوان ورودی استفاده کردند. ویژگی‌ها از طریق ضرایب همبستگی متقابل محاسبه شدند. این مدل به دقت تشخیص تشنج ۹۵.۹۶٪ دست یافت.

آقای یوان و همکاران [۸۹] از ELM و ویژگی‌های دینامیکی غیرخطی استخراج‌شده از EEG در سال ۲۰۱۱ استفاده کردند. آنها از ویژگی‌هایی مانند آنتروپی تقریبی^{۸۸} (ApEN)، شار هرست^{۸۹} و توان مقیاس‌پذیری به‌دست‌آمده از تحلیل نوسانات بدون روند^{۹۰} (DFA) استفاده کردند [۱۶۰]. الگوریتم ELM منجر به دقت تشخیص رضایت‌مند ۹۶.۵٪ شد. آقای خان و همکاران [۹۰] از تحلیل تفکیک خطی ساده^{۹۱} (LDA) همراه با تبدیل موجک گسسته^{۹۲} (DWT) استفاده کردند. این مطالعه به دقت ۹۱.۸۰ درصد رسید. در همان سال، جناب نیکولا و همکاران [۹۱] از آنتروپی جایگشت^{۹۳} (PE) به عنوان ورودی برای SVM استفاده کردند. ترکیب PE و SVM منجر به دقت ۹۳.۸۰٪ شد. آقای ژو و همکاران [۹۲] از

⁸³ Auto-Regressive

⁸⁴ Back-Propagation Neural Network

⁸⁵ Fast Fourier Transform

⁸⁶ Mixture of Experts

⁸⁷ Support Vector Machine

⁸⁸ Approximate Entropy

⁸⁹ Hurst Exponent

⁹⁰ Detrended Fluctuation Analysis

⁹¹ Linear Discriminant Analysis

⁹² Discrete Wavelet Transform

⁹³ Permutation Entropy

لکوناریته^{۹۴} و آنالیز تشخیصی خطی بیزی در EEG داخل مجموعه‌ای استفاده کرد و به دقت ۹۶/۶۷ درصد دست یافت. در سال ۲۰۱۴، کومار و همکاران [۹۳] سیگنال‌های EEG را از طریق تبدیل موجک به باندهای دلتا، تتا، آلفا، بتا و گاما جدا کردند. ویژگی‌های آماری و غیر خطی از این باندها استخراج شد و به یک طبقه بندی کننده SVM وارد شد. کومار و همکاران با این تنظیمات به دقت ۹۷.۵۰ درصد رسیدند. در سال ۲۰۱۶، آقای سونگ و همکاران [۹۴] از SVM به همراه آنتروپی جایگشت وزنی استفاده کردند و به دقت ۹۷/۲۵ درصد دست یافتند. در سال ۲۰۱۶، محققان [۸۱] از تبدیل موجک چند سطحی به عنوان استخراج کننده ویژگی استفاده کردند و آن‌ها را به طبقه بندی کننده ELM اعمال کرد.

در سال ۲۰۱۷، آقای حسینی و همکاران [۹۵] از rs-fMRI و EEG چندوجهی با طبقه بندی کننده CNN برای محلی سازی ناحیه صرع را استفاده کردند. نتیجه این مطالعه p-value نرمال ۱۴-۱.۸۵e و p-seizure با مقدار ۲۷-e-۴.۶۴ حاصل کرد. در همان سال، جناب آرهاریا و همکاران [۸۲] از شبکه عصبی کانولوشنال تک بعدی عمیق ۱۳ لایه برای تشخیص کلاس‌های عادی، پریکتال و تشنج استفاده کردند. آن‌ها داده‌ها را با نرمال سازی Z-score نرمالیزه کردند و نرخ نمونه برداری سیگنال EEG را روی ۱۷۳.۶۱ هرتز تنظیم کردند. این تکنیک به ترتیب به دقت، ویژگی و حساسیت ۸۸.۶۷٪، ۹۰.۰۰٪ و ۹۵.۰۰٪ دست یافته است.

در سال آینده ۲۰۱۸، حسین و همکاران [۹۶] برای تشخیص تشنج صرع از یک شبکه سه لایه LSTM کاملاً متصل یک بعدی به همراه یک طبقه بندی کننده softmax استفاده کرد. این شبکه همچنین شامل یک لایه متراکم توزیع شده در زمان و یک لایه ادغام متوسط بود. آن‌ها به نتایج قانع کننده‌ای از حساسیت، ویژگی و دقت ۱۰۰ درصدی هر کدام در مسائل دو کلاسه، مسائل سه کلاسه و مسائل پنج کلاسی دست یافتند. رویکردهای این مطالعه در دانشگاه بن مورد ارزیابی قرار گرفت. ضبط‌های مجموعه داده‌های EEG بن فقط حاوی یک کانال EEG هستند و هیچ آرتیفکتهای^{۹۵} ندارند. بنابراین، مجموعه داده بن در مقایسه با داده‌های EEG واقعی تفاوت زیادی دارد. در همان سال، لیانگ و همکاران [۸۳] یک طبقه بندی یادگیری عمیق را برای شناسایی تشنج از طریق تصاویر EEG امتحان کرد. آن‌ها رویکرد خود را با یک بازرسی بصری برای شناسایی ناهنجاری‌های صرعی توجیه کردند و به یک نتیجه نسبتاً خوب، با ۸۴٪ حساسیت، ۹۹٪ برای ویژگی، و ۹۹٪ برای دقت، دست یافتند.

^{۹۴} Lacunarity

^{۹۵} Artifacts

۳. مواد و روش‌ها

۳.۱. مقدمه

به علت قدرت بالای سیگنال ECoG و نویز کم این سیگنال در این تحقیق ترجیح داده شد که به جای سیگنال EEG از سیگنال ECoG استفاده شود. چون این سیگنال مستقیم از سطح مغز ضبط میشود دارای قدرت و لتاژی بالا، نویز کمتر نسبت به EEG است. داده های مورد استفاده در این تحقیق از نمونه های حیوانی، موش صحرایی WAG/Rij استخراج و ضبط شد و در ادامه داده ها بعد از پیش پردازش و علامت گذاری به شبکه هوش مصنوعی عمیق از نوع کانولوشنی اعمال شد.



شکل ۳.۱. دیاگرام روال کلی تحقیق.

۳.۲. جمع آوری داده‌ها

۳.۲.۱. موش ها

۱۳ موش صحرایی از نژاد ویستار WAG/Rij با متوسط وزنی ۲۸۰ گرم در این تحقیق استفاده شدند. این موش ها در محل آزمایشگاه فیزیولوژی دانشکده دامپزشکی دانشگاه تبریز نگه داری و مورد آزمایش قرار میگرفتند.


۳.۲.۲. جراحی و کاشت الکترودها

موش های صحرایی با استفاده از تزریق ترکیب دو دارو کتامین^{۹۶} (80 mg/kg) و زایلازین^{۹۷} (20mg/kg) وارد فاز بیهوشی عمیق می شدند. سپس چهار الکترودها با نقطه شروع لامبدا^{۹۸} و مختصات (AP1: *-0.18, AP2: *-0.4, ML1: *+0.3,) و یک الکتروده در قشر پس سر کاشته میشد طبق شکل ۳.۲ جنس الکترودها از پیچ زدزنگ بود و بعد از اتمام کاشت الکترودها محل جراحی و اطراف الکترودها با استفاده از سیمان مخصوص پوشانده و محکم میشد در طول فرایند جراحی موش و سر موش در مهار دستگاه stereotaxic بود.

^{۹۶} Ketamine

^{۹۷} xylazine

^{۹۸} Lambda



شکل ۳.۲. موقعیت الکترود های کاشت شده برای ضبط سیگنال.

۳.۲.۳. ثبت سیگنال ECoG


بعد از گذشت هفت روز از جراحی، اقدام به ضبط سیگنال می کردیم به طوری که دوباره موش را وارد فاز بیهوشی عمیق میکردیم و سپس سر و بدن موش را در دستگاه stereotaxic ثابت می کردیم، با استفاده از یک سیستم الکترونیکی مبتنی بر SOC⁹⁹ (ساخته شده در آزمایشگاه میکروسنسور و میکرو الکترونیک دانشکده مهندسی برق و کامپیوتر دانشگاه تبریز) با فرکانس نمونه برداری ۵۱۲ هرتز و چهار کانال اقدام به ضبط سیگنال می کردیم. فرایند ضبط به طوری بود که بعد از نصب پراب ۱۰ دقیقه در حالت عالی سیگنال ضبط میشد بعد از این مدت با تزریق پنتیل تترازل^{۱۰۰} PTZ^{۱۰۱} (80mg/kg) موش وارد فاز تشنجی میشد این فرایند را هم به مدت ۱۰ دقیقه ضبط میکردیم بعد از اتمام این مدت با تزریق دیازپام^{۱۰۲} فرایند سرکوب تشنج در بدن موش آغاز می شد و موش وارد فاز سرکوب میشد این دوره را نیز به مدت ۱۰ دقیقه ضبط میکردیم در کل تقریبا ۳۰ دقیقه سیگنال از هر موش ضبط میشد.

⁹⁹ system on chip

¹⁰⁰ Pentylene-tetrazol

¹⁰¹ pentylene-tetrazol

^{۱۰۲} یک نوع داروی مسکن



شکل ۳.۳. نحوه اتصال پراب های ضبط سیگنال به الکترودها و چند سیگنال نمونه ضبط شده.

۳.۳. طراحی شبکه عمیق

۳.۳.۱. سامانه ها و کتابخانه های مورد استفاده

تمام محاسبات و پردازش های انجام شده در این تحقیق بر روی یک سامانه ابری محاسباتی و کد نویسی به نام google colab برای شرکت گوگل^{۱۰۳} که بر روی سرور های خود گوگل است انجام شد است. روال کار در این سامانه به گونه ای است که بعد از ثبت نام یک سخت افزار سیال البته با محدودیت خاصی در اختیار شما قرار میدهد که شما می توانید صرفاً با زبان برنامه نویسی پایتون و دستورات لینوکسی کد های خودتان را اجرا کنید. سخت افزار گرافیکی که برای اجرای کد شبکه عمیق ما از طرف این سامانه اختصاص داده شد دارای مشخصات زیر بود:

device_type: "GPU"

name: Tesla T4

compute capability: 7.5

مشاهده میکنیم که این سخت افزار دارای قابلیت محاسبه ۷.۵ است که طبق توضیحات سایت رسمی mathworks کارت گرافیکی با قابلیت محاسبه حداقل ۶.۱ برای فرایند آموزش شبکه های یادگیری ماشین / عمیق مناسب است.

کتابخانه های پایتونی که برای محاسبات و طراحی شبکه از آنها استفاده شده به روال زیر هستند:

TensorFlow: کتابخانه متن بازی که توسط گوگل برای یادگیری ماشین در انواع مختلف توسعه داده شده است.

Keras: یک کتابخانه متن باز به زبان پایتون که بر روی تنسورفلو اجرا میشه

NumPy: کتابخانه ای برای محاسبات علمی و ریاضی در پایتون.

Matplotlib: کتابخانه ای برای نمایش داده ها در پایتون.

۳.۳.۲. پیش پردازش داده ها


تنها فیلتری که بعد از جمع اوری داده های بر کل داده ها اعمال شد یک فیلتر ناچ (فیلتر میان نگذر) ۵۰ هرتز برای حذف نویز برقی شهری بود. به علت اعوجاج های ایجاد شده در روند ضبط سیگنال هنگام تزریق داروها و یا رفتار های پیش بینی نشده به صورت دستی قسمت های مورد نیاز سیگنال طبق جدول زیر از هم تفلیک و جدا شد برای نمونه میتوانید داده های این جدول را با نمونه سیگنال های آورده شده در شکل ۳.۳ مقایسه کنید.

جدول ۳.۱. تفکیک زمانی اولیه سیگنال های مغزی.

نام نمونه	زمان های انتخاب شده در فاز نرمال ثانیه (S)	زمان های انتخاب شده در فاز تشنج ثانیه (S)
RAT_1	30-50	100-780
RAT_2	30-600	650-1200
RAT_3	10-620	660-800 900-120
RAT_4	20-610	660-1220
RAT_5	10-700	790-1350
RAT_6	10-330	800-930

	380-480 570-700	960-1340
RAT_7	10-670	700-930 1010-1350
RAT_8	60-640	670-1250
RAT_9	10-590	790-1240
RAT_10	10-640	680-790 870-960 1030-1160
RAT_11	40-630	690-1260
RAT_12	40-650	690-1370
RAT_13	30-580	640-780 900-1210

سیگنال ها بعد از تفکیک دستی در دو گروه دسته بندی شدند (۱ فاز نرمال ۲ فاز تشنج هر کدام از این دسته ها برای ۱۳ عدد موش باهم به پنجره های ۲ ثانیه با همپوشانی یک ثانیه تقسیم بندی شدند.



شکل ۳.۴. نمونه ای از یک پنجره ۲ ثانیه ای از سیگنال تشنج.

سپس همه داده ها با توجه به فرکانس نمونه برداری و تعداد کانال داری ابعاد (۴، ۱۰۲۴) شدند و در اخر تمام داده ها در یک ماتریس سه بعدی که بعد اول ان تعداد کل داده ها بود چیده شدند (۴، ۱۰۲۴، ۱۳۷۹۸) و بعد از برجسب گذاری دستی دسته ها به صورت تصادفی توزیع شدند. برای توضیح تصادفی هر بسته داده از تابع توزیع نرمال استفاده شد.

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} \quad (۲)$$

۳.۳.۳. انتخاب شبکه عمیق مناسب

با توجه به نوع فرایند کاری این تحقیق شبکه که مورد نیاز ما از نوع طبقه بند با نظارت بود. برای این منظور دو مدل شبکه کاربرد بیشتری دارد شبکه های بازگشتی و شبکه های کانولوشنی که هر کدام انواعی مختلفی دارد. برای انتخاب نوع مناسب از این شبکه ها آزمایشی طراحی شد به طوری که از هر کدام از آنها یک شبکه ساده با ۲ لایه پنهان و پرامتر های هم تراز به صورت جداگانه طراحی شد و داده ها به صورت جداگانه به همه این شبکه های ساده اعمال شد و شبکه که بهترین رفتار و نتیجه را با داده های ما داشت انتخاب شد. طبق این آزمایش شبکه های CNN_2D بهترین نتیجه را در میان بقیه شبکه برای داده های ما داشت نتایج به دست آمده در جدول ۳.۲ قابل مشاهده است.

جدول ۳.۲. نتایج آزمون انتخاب شبکه عمیق مناسب.

نام ساختار شبکه	تعداد لایه	تعداد پارامتر	تعداد دوره مشاهده داده	زمان تقریبی آموزش شبکه	دقت شبکه (درصد)	هزینه محاسباتی شبکه (درصد)	ساختار شبکه
SimpleRNN	۲	۲۰	۱۰۰	۳۷ دقیقه	٪۵۶	٪۶۸	
LSTM	۲	۶۲	۱۰۰	۲ دقیقه	٪۵۴	٪۶۸	
GRU	۲	۵۴	۱۰۰	۲ دقیقه	٪۵۴	٪۶۸	
CNN_1D	۲	۱۶۳۹۶	۱۰۰	۹ ثانیه	٪۶۶	٪۶۰	
CNN_2D	۲	۱۶۴۲۰	۱۰۰	۷ ثانیه	٪۶۷	٪۶۱	


مشاهده میشود که شبکه های کانولوشنی علاوه بر دقت بالا دارای زمان آموزش بسیار کم هستند این پارامتر برای سیستم های افلاین پارامتر کم ارزشی هست اما برای سیستم های آنلاین این پارامتر تاثیر زیادی بر سرعت بهبود و عملکرد سیستم دارد.

۳.۳.۴. طراحی و تنظیم پارامترهای شبکه CNN_2D

۳.۳.۴.۱. لایه Convolutional

لایه کانولوشن هسته اصلی تشکیل دهنده شبکه عصبی کانولوشن است، و توده خروجی آن را میتوان بصورت یک توده سه بعدی از نورون ها تفسیر کرد. به زبان ساده تر یعنی اینکه خروجی این لایه یک توده سه بعدی است. در این لایه ها، شبکه CNN از هسته های مختلف برای ضرب پیچشی کردن داده ورودی و همین طور نقشه ویژگی^{۱۰۴} های میانی استفاده می کند و اینگونه نقشه ویژگی های مختلفی همانند آنچه در شکل ۳.۵ مشاهده می کنید ایجاد می کند. انجام عملیات ضرب پیچشی سه فایده دارد.

۱. مکانیزم اشتراک وزن در هر نقشه ویژگی باعث کاهش شدید تعداد پارامترها می شود.
۲. اتصال محلی، ارتباط بین پیکسل های همسایه را یاد می گیرد.
۳. باعث تغییر ناپذیری و ثبات نسبت به تغییر مکان شی می شود.



شکل ۳.۵. عملیات لایه کانولوشن.

۳.۳.۴.۲. BatchNormalization لایه‌ی

هدف نرمال سازی دسته ای تبدیل داده های ما به گونه ای است که میانگین آن صفر با واریانس یک باشد. بنابراین خروجی یک لایه قبل از وارد کردن آن به لایه بعدی نرمال می شود.

$$\text{Batch mean} \quad \mu_B = \frac{1}{m} \sum_{i=1}^m x_i \quad (۳)$$

$$\text{Batch variance} \quad \sigma_B^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \mu_B)^2 \quad (۴)$$

$$\bar{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} \quad (۵)$$

۳.۳.۴.۳. Pooling لایه‌ی

در این نوع ادغام بزرگترین مقدار در ناحیه‌ای را که فیلتر پوشانده است انتخاب می‌شود؛ بنابراین در این حالت خروجی یک نقشه‌ی ویژگی (Feature Map) است که برجسته‌ترین ویژگی‌های نقشه ویژگی (Feature Map) قبلی را دارد.

۳.۳.۴.۴. Flatten لایه‌ی

این لایه به عنوان مسطح کننده داده نیز شناخته می‌شود. خروجی های به دست آمده از آخرین لایه در یک بردار مسطح می‌شوند تا بتوان از آن به عنوان داده های ورودی لایه آینده استفاده کرد.

۳.۳.۴.۵. Fully-Connected لایه‌ی

معمولاً آخرین لایه های یک شبکه عصبی کانولوشن برای طبقه بندی را لایه های تمام متصل تشکیل می‌دهند. یکی از کاربردهای اصلی لایه تمام متصل در شبکه کانولوشن، استفاده به عنوان طبقه بند یا Classifier است.

۳.۳.۴.۶. Dropout لایه‌ی

در این روش مدل در هریک از لایه ها نورون‌های را به صورت تصادفی حذف میکند. این کار باعث میشه که مدل دچار پدیده بیش برازش نشود.

۳.۳.۴.۷ Activity Regularization لایه‌ی

عملیات نظم‌دهی تغییرات اندکی در شبکه‌های عصبی پیچشی به وجود می‌آورد تا به شکل بهتری تعمیم یابند. این عملیات، شبکه‌های عصبی پیچشی را ترغیب می‌کند تا ویژگی‌های پراکنده و نکاتی از دل مشاهدات خام یاد بگیرد. همین موضوع باعث می‌شود مدل به شکل بهتری بر روی داده‌های دیده نشده عمل کند. در بخش زیر، سه روش نظم‌دهی را معرفی می‌کنیم:

L1 فعالیت به عنوان مجموع مقادیر مطلق محاسبه می‌شود.

L2 فعالیت به عنوان مجموع مقادیر مجذور محاسبه می‌شود.

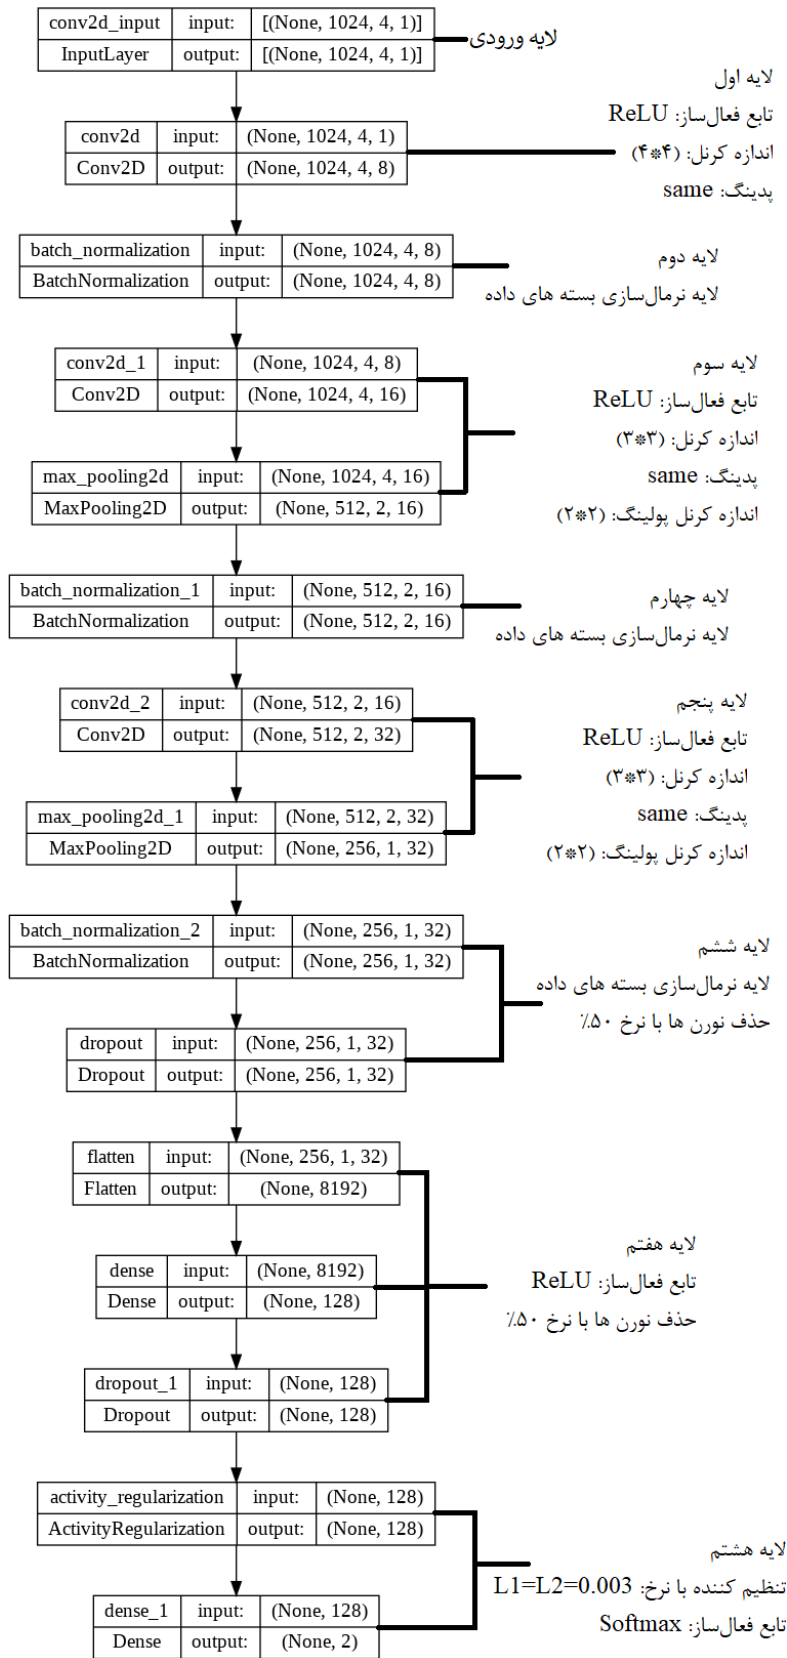
L1-L2 فعالیت به عنوان مجموع مقادیر مطلق و مجموع مقادیر مجذور محاسبه می‌شود.

$$\text{L1 Regularization} \quad \text{cost} = \sum_{i=0}^N (y_i - \sum_{j=0}^M x_{ij} w_j)^2 + \lambda \sum_{j=0}^M |w_j| \quad (۶)$$

$$\text{L2 Regularization} \quad \text{cost} = \sum_{i=0}^N (y_i - \sum_{j=0}^M x_{ij} w_j)^2 + \lambda \sum_{j=0}^M w_j^2 \quad (۷)$$

۳.۳.۴.۸ ساختار نهایی شبکه عمیق طراحی شده

ساختار نهایی شبکه طراحی شده با هشت لایه در شکل ۳.۶ قابل مشاهده است. این شبکه عمیق دارای ۶۰۱۸ نورون و ۱۰۵۵۱۳۰ پارامتر هست که از این تعداد ۱۰۵۵۰۱۸ پارامتر در فرایند آموزش مشارکت داشته. البته لازم به ذکر هست که عمده حجم پارمترها مربوط به لایه تمام اتصال ماقبل لایه آخر هست (۱۰۴۸۷۰۴ پارامتر).



شکل ۳.۶. ساختار نهایی شبکه عمیق CNN_2D.

۳.۳.۵. آموزش شبکه

قبل از این که سراغ آغاز فرایند آموزش شبکه برویم داده ها را برای ارزیابی دقت در مراحل آموزش و بعد از فرایند آموزش به سه قسمت تقسیم کردیم بخش اول که ۱۳٪ درصد کل داده ها (۱۷۹۸ نمونه) را شامل می شد برای داده های تست اختصاص داده شد که شبکه هیچ وقت در فرایند آموزش آنها را نمی دید. بخش دوم که بازهم تقریباً ۱۳٪ (۱۸۰۰ نمونه) کل داده ها را شامل میشد برای ارزش سنجی هر دوره فرایند آموزش استفاده میشد به طوری که این داده ها در فرایند آموزش مشارکت نداشتن ولی در هر دوره برای اندازه گیری دقت و هزینه محاسباتی از این داده ها استفاده می شد. و مابقی داده ها (۱۰۲۰۰ نمونه) تماماً در فرایند آموزش شبکه مشارکت داشتن.




شکل ۳.۷. نحوه تقسیم داده ها در فرایند آموزش شبکه.

با توجه به نتایج به دست آمده بعد از اتمام فرایند آموزش بهترین دقت برای دیتاهای ارزشگذاری یاهمان دیتا های که در فرایند آموزش شرکت نداشتن در دوره ای ۳۲۱ رخ داده است که برابر ۹۶.۲۲٪ است. البته باید توجه داشت که در همین دوره دقت آموزش برابر ۹۹.۴۷٪ است این دقت با نوسان کمتر از ۰.۵٪ تا پایان فرایند آموزش حفظ میشود.


Epoch 321/400

160/160 [=====] - 2s 14ms/step -

loss: 0.0353 - accuracy: 0.9947 - val_loss: 0.2400 - val_accuracy: 0.962



شکل ۳.۹. نمودار تغییرات دقت در هر دوره فرایند آموزش



شکل ۳.۸. نمودار تغییرات خطا در هر دوره فرایند آموزش


۴. نتایج و بحث

۴.۱. نتایج به دست آمده

در پایان برای بررسی دقت و صحت عملکرد شبکه از داده های تست کمک گرفتیم و از روی خروجی طبقه بندی شده که شبکه به ما پیشنهاد داده بود ماتریس درهم ریختگی را تشکیل دادیم و پارامترهای ارزیابی را محاسبه کردیم نتایج به دست آمده به روال زیر بودند.

- دقت و هزینه محاسباتی فرایند تست به ترتیب ۹۵.۲۲٪ و تقریباً ۱۷٪ خطا

loss: 0.1798 - accuracy: 0.9522



شکل ۴.۱. ماتریس درهم ریختگی داده های تست.

برای هر نمونه داده، یکی از چهار حالتی که در ادامه بیان می شود، ممکن است اتفاق بیفتد.

True Positive: نمونه عضو دسته مثبت باشد و عضو همین کلاس تشخیص داده شود مثبت صحیح یا:

False Negative: نمونه عضو کلاس مثبت باشد و عضو کلاس منفی تشخیص داده شود منفی کاذب یا:

True Negative: نمونه عضو کلاس منفی باشد و عضو همین کلاس تشخیص داده شود منفی صحیح یا:

False Positive: نمونه عضو کلاس منفی باشد و عضو کلاس مثبت تشخیص داده شود مثبت کاذب یا:

حساسیت به معنی نسبتی از موارد مثبت است که آزمایش آن‌ها را به درستی به عنوان نمونه مثبت تشخیص داده است. این پارامتر به صورت زیر محاسبه می‌شود:

$$\text{Sensitivity (TPR)} = \text{TP} / (\text{TP} + \text{FN}) \quad (۸)$$

{'Sensitivity': **0.9303097345132744**}

ویژگی به معنی نسبتی از موارد منفی است که آزمایش آن‌ها را به درستی به عنوان نمونه منفی تشخیص داده است. این پارامتر به صورت زیر محاسبه می‌شود:

$$\text{Specificity (TNR)} = \text{TN} / (\text{TN} + \text{FP}) \quad (۹)$$

{'Specificity_recall ': **0.9742729306487695**}

صحت یعنی از بین تمام کلاسهای مثبتی که به طور صحیح پیش بینی کرده ایم، چند نفر در واقع مثبت هستند. این پارامتر به صورت زیر محاسبه می‌شود:

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP}) \quad (۱۰)$$

{'Precision': **0.9733796296296297**}

معیار F1 اگر بخواهیم همزمان هر دو معیار صحت و حساسیت فراخوانیرا در ارزیابی مدل دخیل باشند از این معیار استفاده می‌کنیم:

$$\text{F1_score} = 2 * ((\text{recall} * \text{Precision}) / (\text{recall} + \text{Precision})) \quad (۱۱)$$

{'F1_score': **0.9513574660633485**}

۴.۲. بحث و نتیجه گیری

در مقایسه ای که با منابع مشابه انجام شده است مشاهده میشود که حجم داده ها میتواند عامل موثری در دقت و حساسیت تشخیص شبکه باشد. مرجع [۳۴] به علت شباهت از لحاظ منبع حیوانی سیگنال های جمع اوری شده با این تحقیق است اما از لحاظ حجم بسیار متفاوت است. تفاوت تعداد کانال میتواند به علت اندازه مجموعه منبع سیگنال هم باشد، علاوه بر محدودیت های امکانات ضبط. فرکانس نمونه برداری با توجه به تفکیک ریتم های سیگنال های مغزی بیشتر از ۱۰۰ هرتز خیلی دارای اطلاعات ارزشمند نیست به همین خاطر میتوان با فرکانس های کمتر از فرکانس نمونه برداری ۵۱۲ هم اقدام به ضبط سیگنال کرد. شبکه های طراحی شده عموماً به علت افزایش دقت از حداقل دو شاخه موازی استفاده کرده بودند اما ما با فرض پیاده سازی سخت افزاری سعی در ساده سازی شبکه همراه با افزایش دقت و حساسیت را داشتیم.

جدول ۴.۱. مقایسه نتایج و نوع داده ها با پژوهش های دیگر.

سال	مرجع	منبع داده ها	تعداد کانال نمونه بردار	فرکانس نمونه برداری	حجم کل داده ها	طول هر بسته داده	مدل شبکه	تعداد لایه شبکه	دقت	حساسیت
۲۰۱۹	[33]	EEG-Bonn Barcelona-Bern	۱۹ ۱۹	۱۷۳۶ ۵۱۲	۱۹۶ دقیقه ~۲۰ ساعت	-	CNN	۵	٪۹۹ ٪۹۱	-
۲۰۱۹	[34]	Dog Epilepsy Kaggle	۱۶	۴۰۰	تقریباً ۶۰۰ ساعت	-	CNN	شبکه دارای دولایه انشعابی موازی ۱۰	-	٪۷۹
۲۰۲۳	[35]	CHB-MIT SWEC-ETHZ	۱۹ ۱۱	۲۵۶ ۵۱۲	۳۳۵.۵ ساعت ۴.۴۵ ساعت	۵ ثانیه ۱۰ ثانیه	CNN سه بعدی	شبکه دارای دولایه انشعابی موازی ۱۳	-	٪۹۵ ٪۹۷
۲۰۲۳	این تحقیق	جمع اوری شده از موش صحرای نژاد ویستار	۴	۵۱۲	۲۳۰ دقیقه	۲ ثانیه	CNN	۸	٪۹۵	٪۹۳

۴.۳. پیشنهادات

به منظور ادامه این تحقیق در زمینه تشخیص و پیش بینی تشنجات صرعی از روی سیگنال های مغزی پیشنهاد های زیر
ارایه میگردد:

۱. از سیگنال های EEG که نیازی به تهاجم پزشکی ندارد به جای سیگنال ECOG استفاده شود.
۲. ساختار به دست آمده در این پایان نامه بر روی یک سخت افزار پیاده سازی شود.
۳. سعی بر افزودن داده ها از طریق تکرار روند ضبط آزمایشگاهی شود.
۴. از ساختار های چند شاخه و انشعابی در شبکه عمیق استفاده شود.

- [1] Kälviäinen, R. (2016). Epilepsia on muutakin kuin kohtauksia. *Teoksessa Kälviäinen R., Järviseu-Hulkkonen, M., Keränen, T. & Rantala, H.(toim.) Epilepsia, 1.*
- [2] Fisch, B. J. (2009). *Epilepsy and intensive care monitoring: principles and practice.* Demos Medical Publishing.
- [3] Nie, Y., Lee, J., Yoon, S., & Park, D. S. (2019). A multi-stage convolution machine with scaling and dilation for human pose estimation. *KSII Transactions on Internet and Information Systems (TIIS), 13(6)*, 3182-3198.
- [4] Fisch, B. J. (2009). *Epilepsy and intensive care monitoring: principles and practice.* Demos Medical Publishing.
- [5] Fisher, R. S., Boas, W. V. E., Blume, W., Elger, C., Genton, P., Lee, P., & Engel Jr, J. (2005). Epileptic seizures and epilepsy: definitions proposed by the International League Against Epilepsy (ILAE) and the International Bureau for Epilepsy (IBE). *Epilepsia, 46(4)*, 470-472.
- [6] Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2017). Imagenet classification with deep convolutional neural networks. *Communications of the ACM, 60(6)*, 84-90.
- [7] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 770-778).
- [8] Huang, G., Liu, Z., Van Der Maaten, L., & Weinberger, K. Q. (2017) Densely connected convolutional networks. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 4700-4708.
- [9] Shahbazi, M., & Aghajan, H. (2018, November). A generalizable model for seizure prediction based on deep learning using CNN-LSTM architecture. In *2018 IEEE Global Conference on Signal and Information Processing (GlobalSIP)* (pp. 469-473). IEEE.
- [10] Liu, J., Musialski, P., Wonka, P., & Ye, J. (2012). Tensor completion for estimating missing values in visual data. *IEEE transactions on pattern analysis and machine intelligence, 35(1)*, 208-220.
- [11] Tran, D. (2015) Learning spatiotemporal features with 3D convolutional networks. DOI:10.1109/ICCV.2015.510

- [12] Stafstrom, C. E., & Carmant, L. (2015). Seizures and epilepsy: an overview for neuroscientists. *Cold Spring Harbor perspectives in medicine*, 5(6), a022426.
- [13] Kälviäinen, R., & Erikson, K. (2016a) 2. Mitä epilepsia on? In R. Kälviäinen, M. Järvisoutu-Hulkkonen, T. Keränen & H. Rantala (Eds.), *Epilepsia* (pp. 12-19). Printon, Tallinna: Kustannus Oy Duodecim
- [14] Scheffer, I. E., Berkovic, S., Capovilla, G., Connolly, M. B., French, J., Guilhoto, L., Hirsch, E., Jain, S., Mathern, G. W., Moshé, S. L., Nordli, D. R., Perucca, E., Tomson, T., Wiebe, S., Zhang, Y. & Zuberi, S. M. (2017) ILAE classification of the epilepsies: Position paper of the ILAE commission for classification and terminology. *Epilepsia*, 58(4), 512-521. DOI:10.1111/epi.13709.
- [15] Centeno, M., & Carmichael, D. W. (2014) Network connectivity in epilepsy: Resting state fMRI and EEG-fMRI contributions. *Frontiers in Neurology*, 5, 93. DOI:10.3389/fneur.2014.00093.
- [16] Bancaud, J., Henriksen, O., Rubio-Donnadieu, F., Seino, M., & Dreifuss, F. E. (1981) Proposal for revised clinical and electroencephalographic classification of epileptic seizures. from the commission on classification and terminology of the international league against epilepsy. *Epilepsia*, 22(4), 489-501.
- [17] Kälviäinen, R., & Erikson, K. (2016b) *Epilepsian diagnosointi*. *Epilepsia* (pp. 22-30). Tallinna: Kustannus Oy Duodecim.
- [18] Mäkinen, N. (2020). Deep Learning Approach for Epileptic Seizure Detection.
- [19] Van Wagenen, W. P., & Herren, R. Y. (1940). Surgical division of commissural pathways in the corpus callosum: relation to spread of an epileptic attack. *Archives of Neurology & Psychiatry*, 44(4), 740-759.
- [20] Blume, H. (1997) Corpus callosotomy. URL: <https://www.epilepsy.com/learn/professionals/diagnosis/treatment/surgery/corpus-callosotomy>. Accessed 12.2.2019.
- [21] Trinka, E., Cock, H., Hesdorffer, D., Rossetti, A. O., Scheffer, I. E., Shinnar, S., ... & Lowenstein, D. H. (2015). A definition and classification of status epilepticus—Report of the ILAE Task Force on Classification of Status Epilepticus. *Epilepsia*, 56(10), 1515-1523.
- [22] Mervaala, E., & Jäntti, V. (2006). Status epilepticus ja hoidon seuranta. In *Kliininen neurofysiologia* (pp. 199-203). Duodecim.

- [23] Tatum, W. O., Husai, A. M., Benbadis, S. R., & Kaplan, P. W. (2008). Normal eeg. *Handbook of EEG interpretation. USA: Demos Medical Publishing*, 1-50.
- [24] Mervaala, E., Haaksiluoto, E., Himanen, S. L., Jääskeläinen, S., Kallio, M., Vanhatalo, S., ... & Rusanen, S. (2019). Kliininen neurofysiologia.
- [25] Britton, J. W., Frey, L. C., Hopp, J. L., Korb, P., Koubeissi, M. Z., Lievens, W. E., ... & St Louis, E. K. (2016). Electroencephalography (EEG): An introductory text and atlas of normal and abnormal findings in adults, children, and infants.
- [26] Huttunen, J., Tolonen, U., & Partanen, J. (2006). EEG: n fysiologiaa ja patofysiologiaa. In *Kliininen neurofysiologia* (pp. 50-64). Duodecim.
- [27] Britton, J. W., Frey, L. C., Hopp, J. L., Korb, P., Koubeissi, M. Z., Lievens, W. E., ... & St Louis, E. K. (2016). Electroencephalography (EEG): An introductory text and atlas of normal and abnormal findings in adults, children, and infants.
- [28] Koivu, M., Eskola, H., & Tolonen, U. (2006). EEG: n rekisteröinti, aktivaatiot ja lausunto. *Kirjassa Partanen J, Falck B, Hasan J, Jäntti V, Salmi T, Tolonen U, toim. Kliininen neurofysiologia. Helsinki: Kustannus Oy Duodecim*, 65-83.
- [29] Tolonen, U., & Partanen, J. (2006). EEG-tutkimuksen kliininen käyttö: aiheet ja EEG-häiriön löydöstyytit. In *Kliininen neurofysiologia* (pp. 144-154). Duodecim.
- [30] Tatum IV, W., & Tatum, W. O. (2017). Artifact and ambulatory EEG. *Ambulatory EEG Monitoring. 1st ed. New York, NY: demosMEDICAL*, 41-73.
- [31] Fisher, R. S., Scharfman, H. E., & DeCurtis, M. (2014). How can we identify ictal and interictal abnormal activity?. *Issues in Clinical Epileptology: A View from the Bench*, 3-23.
- [32] Beniczky, S., Aurlen, H., Brøgger, J. C., Hirsch, L. J., Schomer, D. L., Trinka, E., ... & Herman, S. T. (2017). Standardized computer-based organized reporting of EEG: SCORE—Second version. *Clinical Neurophysiology*, 128(11), 2334-2346.
- [33] Lu, D., & Triesch, J. (2019). Residual deep convolutional neural network for eeg signal classification in epilepsy. *arXiv preprint arXiv:1903.08100*.
- [34] Nejedly, P., Kremen, V., Sladky, V., Nasser, M., Guragain, H., Klimes, P., ... & Worrell, G. A. (2019). Deep-learning for seizure forecasting in canines with epilepsy. *Journal of neural engineering*, 16(3), 036031.

- [35] Xu, Y., Yang, J., Ming, W., Wang, S., & Sawan, M. (2023). Deep Learning for Short-Latency Epileptic Seizure Detection with Probabilistic Classification. *arXiv preprint arXiv:2301.03465*.
- [37] Kane, N., Acharya, J., Beniczky, S., Caboclo, L., Finnigan, S., Kaplan, P. W., ... & van Putten, M. J. (2017). A revised glossary of terms most commonly used by clinical electroencephalographers and updated proposal for the report format of the EEG findings. Revision 2017. *Clinical neurophysiology practice*, 2, 170.
- [38] Tolonen, U., & Lehtinen, I. (2006). Aikuisen normaali EEG. *Kliininen neurofysiologia*, 109-128.
- [39] Lauronen, L., Vanhatalo, S., Heinonen, H., Kallio, M., & Mervaala, E. (2019). Normaali ja poikkeava EEG. In *Kliininen neurofysiologia* (pp. 132-149). Kustannus Oy Duodecim.
- [40] Tatum IV, W. O. (2021). *Handbook of EEG interpretation*. Springer Publishing Company.
- [41] Vakkuri, A., Yli-Hankala, A., Särkelä, M., Lindgren, L., Mennander, S., Korttila, K., ... & Jäntti, V. (2001). Sevoflurane mask induction of anaesthesia is associated with epileptiform EEG in children. *Acta anaesthesiologica scandinavica*, 45(7), 805-811.
- [42] Kaibara, M., & Blume, W. T. (1988). The postictal electroencephalogram. *Electroencephalography and clinical neurophysiology*, 70(2), 99-104.
- [43] Miller, K. J., Hermes, D., & Staff, N. P. (2020). The current state of electrocorticography-based brain-computer interfaces. *Neurosurgical focus*, 49(1), E2.
- [44] Crespel, A., & Gélisse, P. (2005). *Atlas of Electroencephalography: Activation Procedures and Artifacts. awake and sleep EEG* (Vol. 1). John Libbey Eurotext.
- [45] Sainio, K. (2006). EEG: n artefaktit ja valvonta. In *Kliininen neurofysiologia* (pp. 98-108). Duodecim.
- [46] Cohen, M. X. (2014). *Analyzing neural time series data: theory and practice*. MIT press.
- [47] Delorme, A., Sejnowski, T., & Makeig, S. (2007). Enhanced detection of artifacts in EEG data using higher-order statistics and independent component analysis. *Neuroimage*, 34(4), 1443-1449.
- [48] Nwankpa, C., Ijomah, W., Gachagan, A., & Marshall, S. (2018). Activation functions: Comparison of trends in practice and research for deep learning. *arXiv preprint arXiv:1811.03378*.

- [49] Sze, V., Chen, Y. H., Yang, T. J., & Emer, J. S. (2017). Efficient processing of deep neural networks: A tutorial and survey. *Proceedings of the IEEE*, 105(12), 2295-2329.
- [50] Agostinelli, F., Hocquet, G., Singh, S., & Baldi, P. (2018). From reinforcement learning to deep reinforcement learning: An overview. In *Braverman Readings in Machine Learning. Key Ideas from Inception to Current State: International Conference Commemorating the 40th Anniversary of Emmanuil Braverman's Decease, Boston, MA, USA, April 28-30, 2017, Invited Talks* (pp. 298-328). Springer International Publishing.
- [51] LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *nature*, 521(7553), 436-444.
- [52] Gori, M., & Tesi, A. (1992). On the problem of local minima in backpropagation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 14(1), 76-86.
- [53] Caruana, R., Lawrence, S., & Giles, C. (2000). Overfitting in neural nets: Backpropagation, conjugate gradient, and early stopping. *Advances in neural information processing systems*, 13.
- [54] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: a simple way to prevent neural networks from overfitting. *The journal of machine learning research*, 15(1), 1929-1958.
- [55] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT press.
- [56] Wang, J., Chen, Y., Hao, S., Peng, X., & Hu, L. (2019). Deep learning for sensor-based activity recognition: A survey. *Pattern recognition letters*, 119, 3-11.
- [57] Kiranyaz, S., Avci, O., Abdeljaber, O., Ince, T., Gabbouj, M., & Inman, D. J. (2021). 1D convolutional neural networks and applications: A survey. *Mechanical systems and signal processing*, 151, 107398.
- [58] Yang, J., Nguyen, M. N., San, P. P., Li, X. L., & Krishnaswamy, S. (2015, June). Deep convolutional neural networks on multichannel time series for human activity recognition. In *Twenty-fourth international joint conference on artificial intelligence*.
- [59] Murad, A., & Pyun, J. Y. (2017). Deep recurrent neural networks for human activity recognition. *Sensors*, 17(11), 2556.
- [60] Kiranyaz, S., Avci, O., Abdeljaber, O., Ince, T., Gabbouj, M., & Inman, D. J. (2021). 1D convolutional neural networks and applications: A survey. *Mechanical systems and signal processing*, 151, 107398.

- [61] Yadav, N., Yadav, A., & Kumar, M. (2015). *An introduction to neural network methods for differential equations* (Vol. 1, p. 114). Berlin: Springer.
- [62] Malhotra, P., Vig, L., Shroff, G., & Agarwal, P. (2015, April). Long Short Term Memory Networks for Anomaly Detection in Time Series. In *ESANN* (Vol. 2015, p. 89).
- [63] Schmidhuber, J., & Hochreiter, S. (1997). Long short-term memory. *Neural Comput*, 9(8), 1735-1780.
- [64] Yang, J., Nguyen, M. N., San, P. P., Li, X. L., & Krishnaswamy, S. (2015, June). Deep convolutional neural networks on multichannel time series for human activity recognition. In *Twenty-fourth international joint conference on artificial intelligence*.
- [65] Kiranyaz, S., Avci, O., Abdeljaber, O., Ince, T., Gabbouj, M., & Inman, D. J. (2021). 1D convolutional neural networks and applications: A survey. *Mechanical systems and signal processing*, 151, 107398.
- [66] Yadav, N., Yadav, A., & Kumar, M. (2015). *An introduction to neural network methods for differential equations* (Vol. 1, p. 114). Berlin: Springer.
- [67] Gers, F. A., Eck, D., & Schmidhuber, J. (2001). Applying LSTM to time series predictable through time-window approaches. In *Artificial Neural Networks—ICANN 2001: International Conference Vienna, Austria, August 21–25, 2001 Proceedings 11* (pp. 669-676). Springer Berlin Heidelberg.
- [68] Schuster, M., & Paliwal, K. K. (1997). Bidirectional recurrent neural networks. *IEEE transactions on Signal Processing*, 45(11), 2673-2681.
- [69] Cho, K., Van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning phrase representations using RNN encoder-decoder for statistical machine translation. *arXiv preprint arXiv:1406.1078*.
- [70] Kuzborskij, I., & Lampert, C. (2018, July). Data-dependent stability of stochastic gradient descent. In *International Conference on Machine Learning* (pp. 2815-2824). PMLR.
- [71] Masters, D., & Luschi, C. (2018). Revisiting small batch training for deep neural networks. *arXiv preprint arXiv:1804.07612*.
- [72] Prechelt, L. (2012). Early stopping—but when?. *Neural networks: tricks of the trade: second edition*, 53-67.
- [73] Bengio, Y. (2012). Practical recommendations for gradient-based training of deep architectures. *Neural Networks: Tricks of the Trade: Second Edition*, 437-478.

- [74] Bobak, S., Kevin, S., & Ziyu, W. (2015). Adams Ryan P, and Freitas Nando de. *Taking the human out of the loop: A review of bayesian optimization. Proceedings of the IEEE*, 104(1), 148-175.
- [75] MathWorks Inc. (2019) Deep learning for signal processing with MATLAB. MathWorks Inc. URL: <https://se.mathworks.com/campaigns/offers/deep-learning-for-signalprocessing-white-paper.html>. Accessed 5.6.2019
- [76] Bishop, C. M. (1995). *Neural networks for pattern recognition*. Oxford university press.
- [77] Moniz, N., Branco, P., & Torgo, L. (2017). Resampling strategies for imbalanced time series forecasting. *International Journal of Data Science and Analytics*, 3, 161-181.
- [78] Sharmila, A. (2018). Epilepsy detection from EEG signals: A review. *Journal of medical engineering & technology*, 42(5), 368-380.
- [79] Subasi, A. (2007). EEG signal classification using wavelet feature extraction and a mixture of expert model. *Expert Systems with Applications*, 32(4), 1084-1093.
- [80] Chandaka, S., Chatterjee, A., & Munshi, S. (2009). Cross-correlation aided support vector machine classifier for classification of EEG signals. *Expert Systems with Applications*, 36(2), 1329-1336.
- [81] Song, Z., Wang, J., Cai, L., Deng, B., & Qin, Y. (2016, June). Epileptic seizure detection of electroencephalogram based on weighted-permutation entropy. In *2016 12th World Congress on Intelligent Control and Automation (WCICA)* (pp. 2819-2823). IEEE.
- [82] Acharya, U. R., Fujita, H., Oh, S. L., Hagiwara, Y., Tan, J. H., & Adam, M. (2017). Application of deep convolutional neural network for automated detection of myocardial infarction using ECG signals. *Information Sciences*, 415, 190-198.
- [83] Hussein, R., Palangi, H., Ward, R., & Wang, Z. J. (2018). Epileptic seizure detection: A deep learning approach. *arXiv preprint arXiv:1803.09848*.
- [84] <https://iranepilepsy.org>
- [85] He, K., Zhang, X., Ren, S., & Sun, J. (2016) Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 770-778.

- [86] Aarabi, A. (2006) Automated neonatal seizure detection: A multistage classification system through feature selection based on relevance and redundancy analysis. *Clinical Neurophysiology*, 117(2), 328-340. DOI:10.1016/j.clinph.2005.10.006
- [87] Polat, K., & Güneş, S. (2007) Classification of epileptiform EEG using a hybrid system based on decision tree classifier and fast fourier transform. *Applied Mathematics and Computation*, 187(2), 1017-1026.
- [88] Mirowski, P. W. (2008) Comparing SVM and convolutional networks for epileptic seizure prediction from intracranial EEG. DOI:10.1109/MLSP.2008.4685487
- [89] Yuan, Q. (2011) Epileptic EEG classification based on extreme learning machine and nonlinear features. *Epilepsy Research*, 96(1-2), 29-38. DOI:10.1016/j.eplepsyres.2011.04.013
- [90] Khan, Y. U. (2012) Automated seizure detection in scalp EEG using multiple wavelet scales. DOI:10.1109/ISPCC.2012.6224361
- [91] Nicolaou, N. (2012) Detection of epileptic electroencephalogram based on permutation entropy and support vector machines. *Expert Systems with Applications*, 39(1), 202-209. DOI:10.1016/j.eswa.2011.07.008
- [92] Weidong Zhou. (2013) Epileptic seizure detection using lacunarity and bayesian linear discriminant analysis in intracranial EEG. *IEEE Transactions on Biomedical Engineering*, 60(12), 3375-3381. DOI:10.1109/TBME.2013.2254486
- [93] Kumar, A. (2014) Machine learning approach for epileptic seizure detection using wavelet analysis of EEG signals. DOI:10.1109/MedCom.2014.7006043
- [94] Song, Z., Wang, J., Cai, L., Deng, B. & Qin, Y. (2016) *Epileptic seizure detection of electroencephalogram based on weighted-permutation entropy*. DOI:10.1109/WCICA.2016.7578764
- [95] Hosseini, M., Tran, T. X., Pompili, D., Elisevich, K. & Soltanian-Zadeh, H. (2017) *Deep Learning with Edge Computing for Localization of Epileptogenicity Using Multimodal rs-fMRI and EEG Big Data*. DOI:10.1109/ICAC.2017.41
- [96] Hussein, R., Palangi, H., Ward, R., & Wang, Z. J. (2018c) Epileptic seizure detection: A deep learning approach.

Surname: Mostafa		Last name: Piran Shendershami	
Thesis Title: Design of epileptic activity detection system using deep learning methods from electrocorticographic signals in rats			
Supervisors: Dr. Javad Fronchi Advisor: Dr. Emad Khalilzadeh			
Degree: M.Sc	Major: Electronic	Field: Integrated Circuit	
University: university of Tabriz		Faculty: Electric and Computer	Page: 65
Keyword: Seizure Detection, electrocorticography (ECoG), Electroencephalogram (EEG), deep learning, Pentylenetetrazol (PTZ), convolutional network, epilepsy.			
Abstract: <p>According to the World Health Organization, epilepsy is the most common brain disorder that affects approximately fifty million people worldwide. Epilepsy diagnosis relies on manual EEG inspection, which is error-prone and time-consuming. Automatic diagnosis of epileptic seizure from EEG or ECoG signal can reduce diagnosis time and facilitate treatment targeting for patients. Current detection approaches mainly rely on features that are manually designed by domain experts. The features are inflexible for recognizing a variety of complex patterns in large volumes of EEG data. In addition, EEG and ECoG signals are non-constant and seizure patterns vary across patients and recording sessions. EEG and ECoG data always contain many types of noise, which negatively affect the accuracy of epileptic seizure diagnosis. To address these challenges, deep learning approaches are reviewed in this paper. The data used in this research were collected from animal samples (gerbils) and seizures were caused abnormally by drugs. Earth series data are applied to deep learning network without any special filter. The only filter used is the 50 Hz notch filter of the utility power. After studying and comparing, convolutional networks were selected and used to classify the data of this research. The best result was obtained with 95.22% accuracy and 17.98% error. The designed network produced promising results for the construction of personalized seizure detectors. Not enough data was available to increase accuracy and reduce error.</p>			



University of Tabriz

Faculty of Electrical and Computer Engineering

Electronics Engineering Department

Thesis for the Degree of Master of Science in Electrical Engineering

Title

**Design of epileptic activity detection system using deep learning methods from
electrocorticographic signals in rats**

Supervisors

Dr. Javad Fronchi

Advisor

Dr. Emad Khalilzadeh

Researcher

Mostafa Piran Shendershami

February 2023